Big Data Real-Time Analytics com Python e Spark

Seja muito bem-vindo(a)!

Processando Big Data com Apache Spark

Por que Aprender Apache Spark?

Como Vamos Estudar o Spark?

Como Vamos Estudar o Spark?

- Capítulo 7 - Arquitetura do Spark, Transformações, Ações, PySpark
- Capítulo 8 - Spark SQL
- Capítulo 9 - Spark Streaming e Análise de Dados em Tempo Real
- Capítulo 10 - Machine Learning em Streaming de Dados com Spark MLlib

Big Data Real-Time Analytics com Python e Spark

O Spark é um tema avançado!

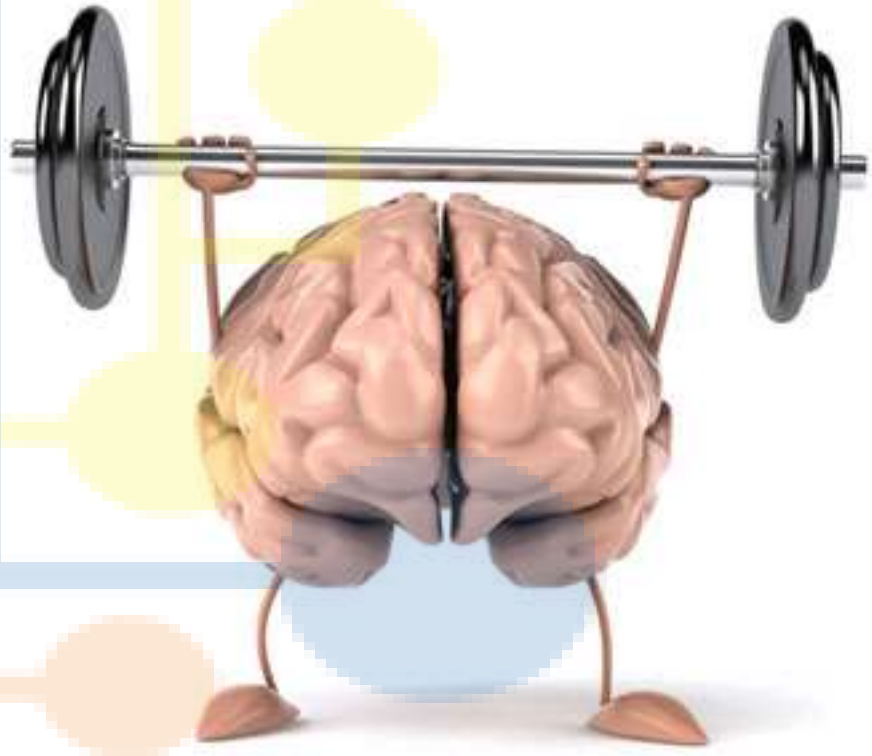

Big Data Real-Time Analytics com Python e Spark

A dedicação é o combustível que nos move.
Ela é a responsável pelo nosso sucesso.

Apache Spark e Big Data

Apache Spark e Big Data

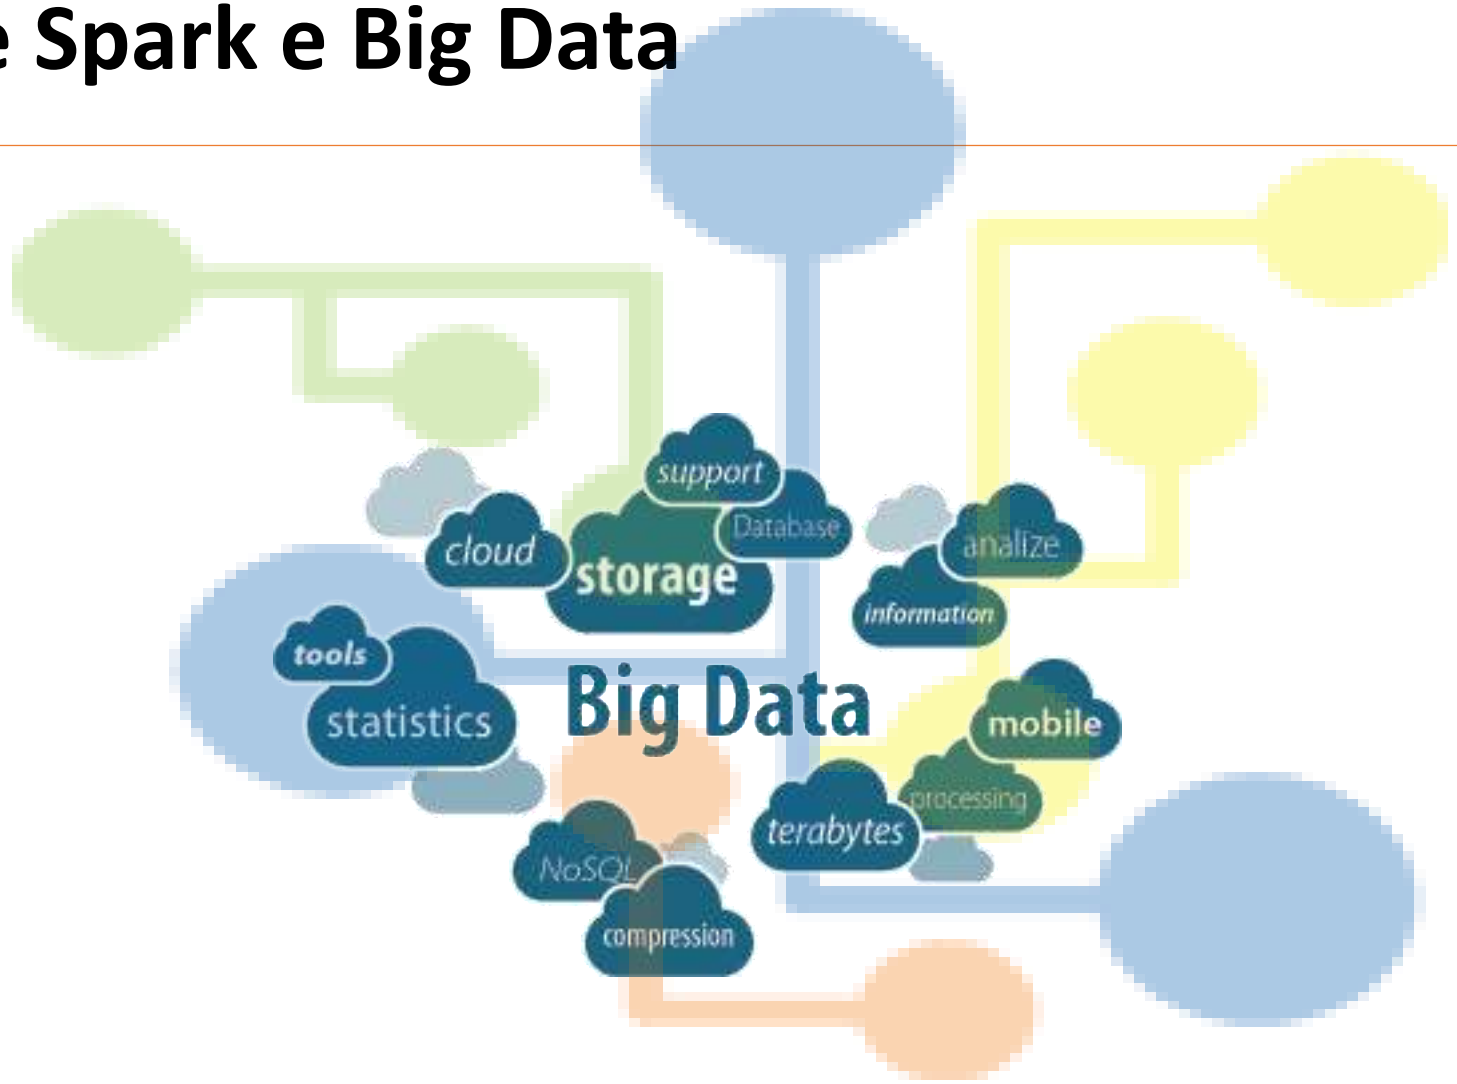

Apache Spark e Big Data

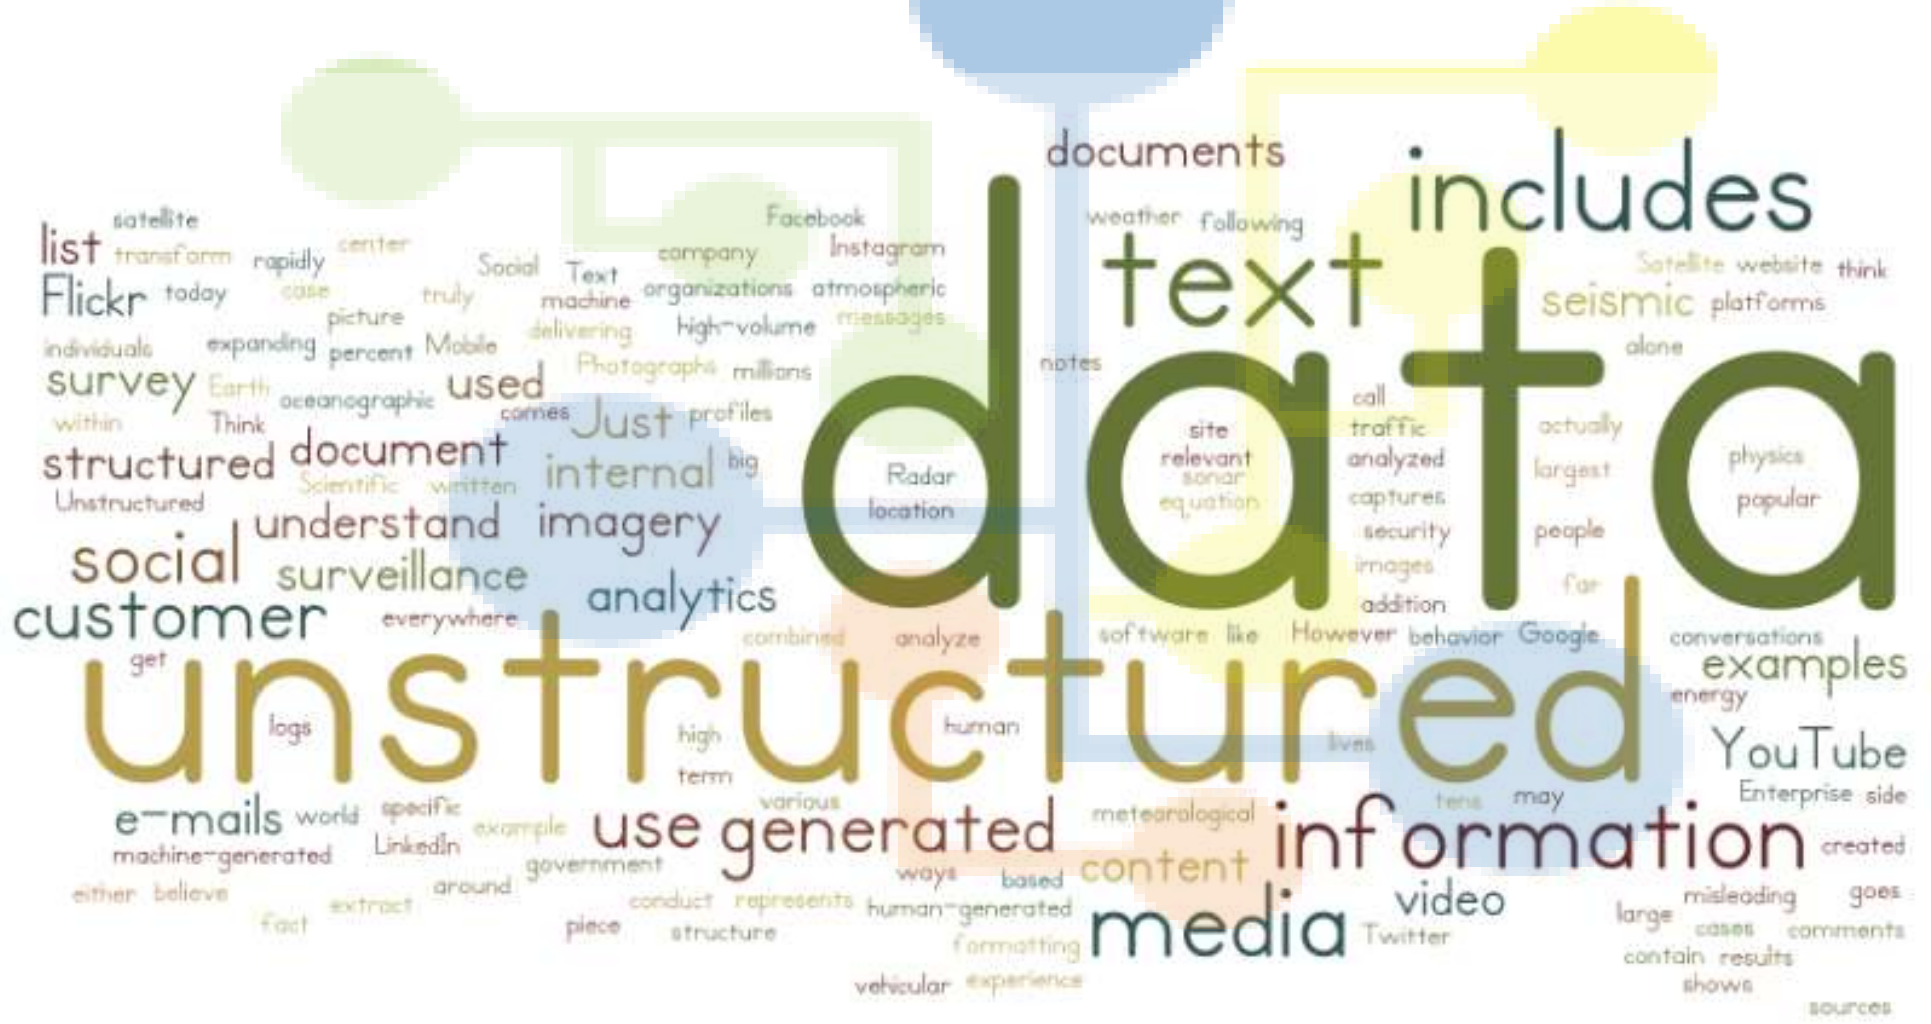

Apache Spark e Big Data

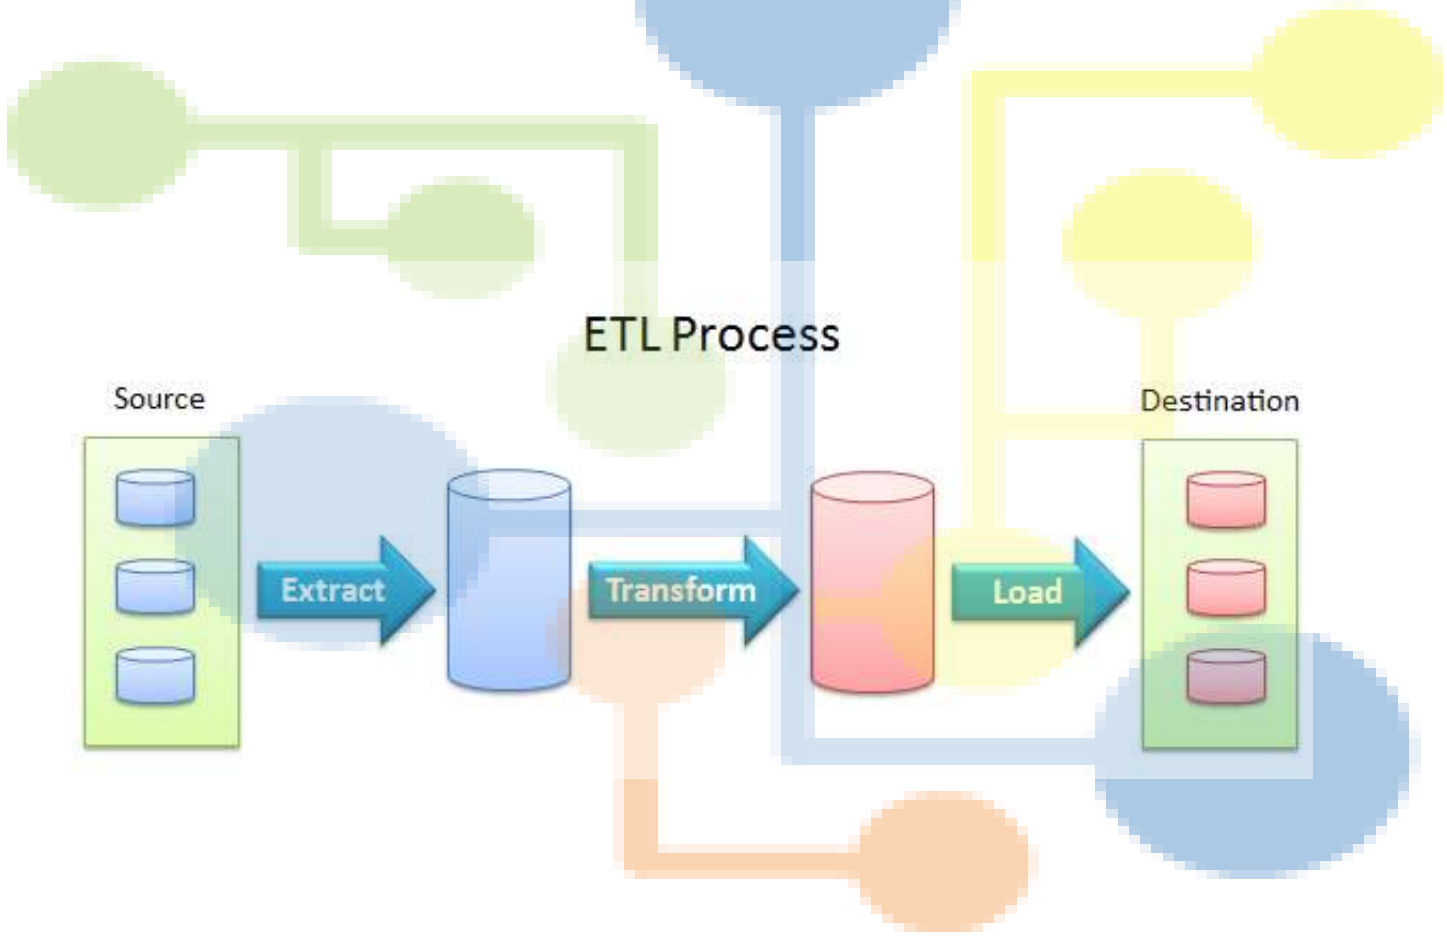

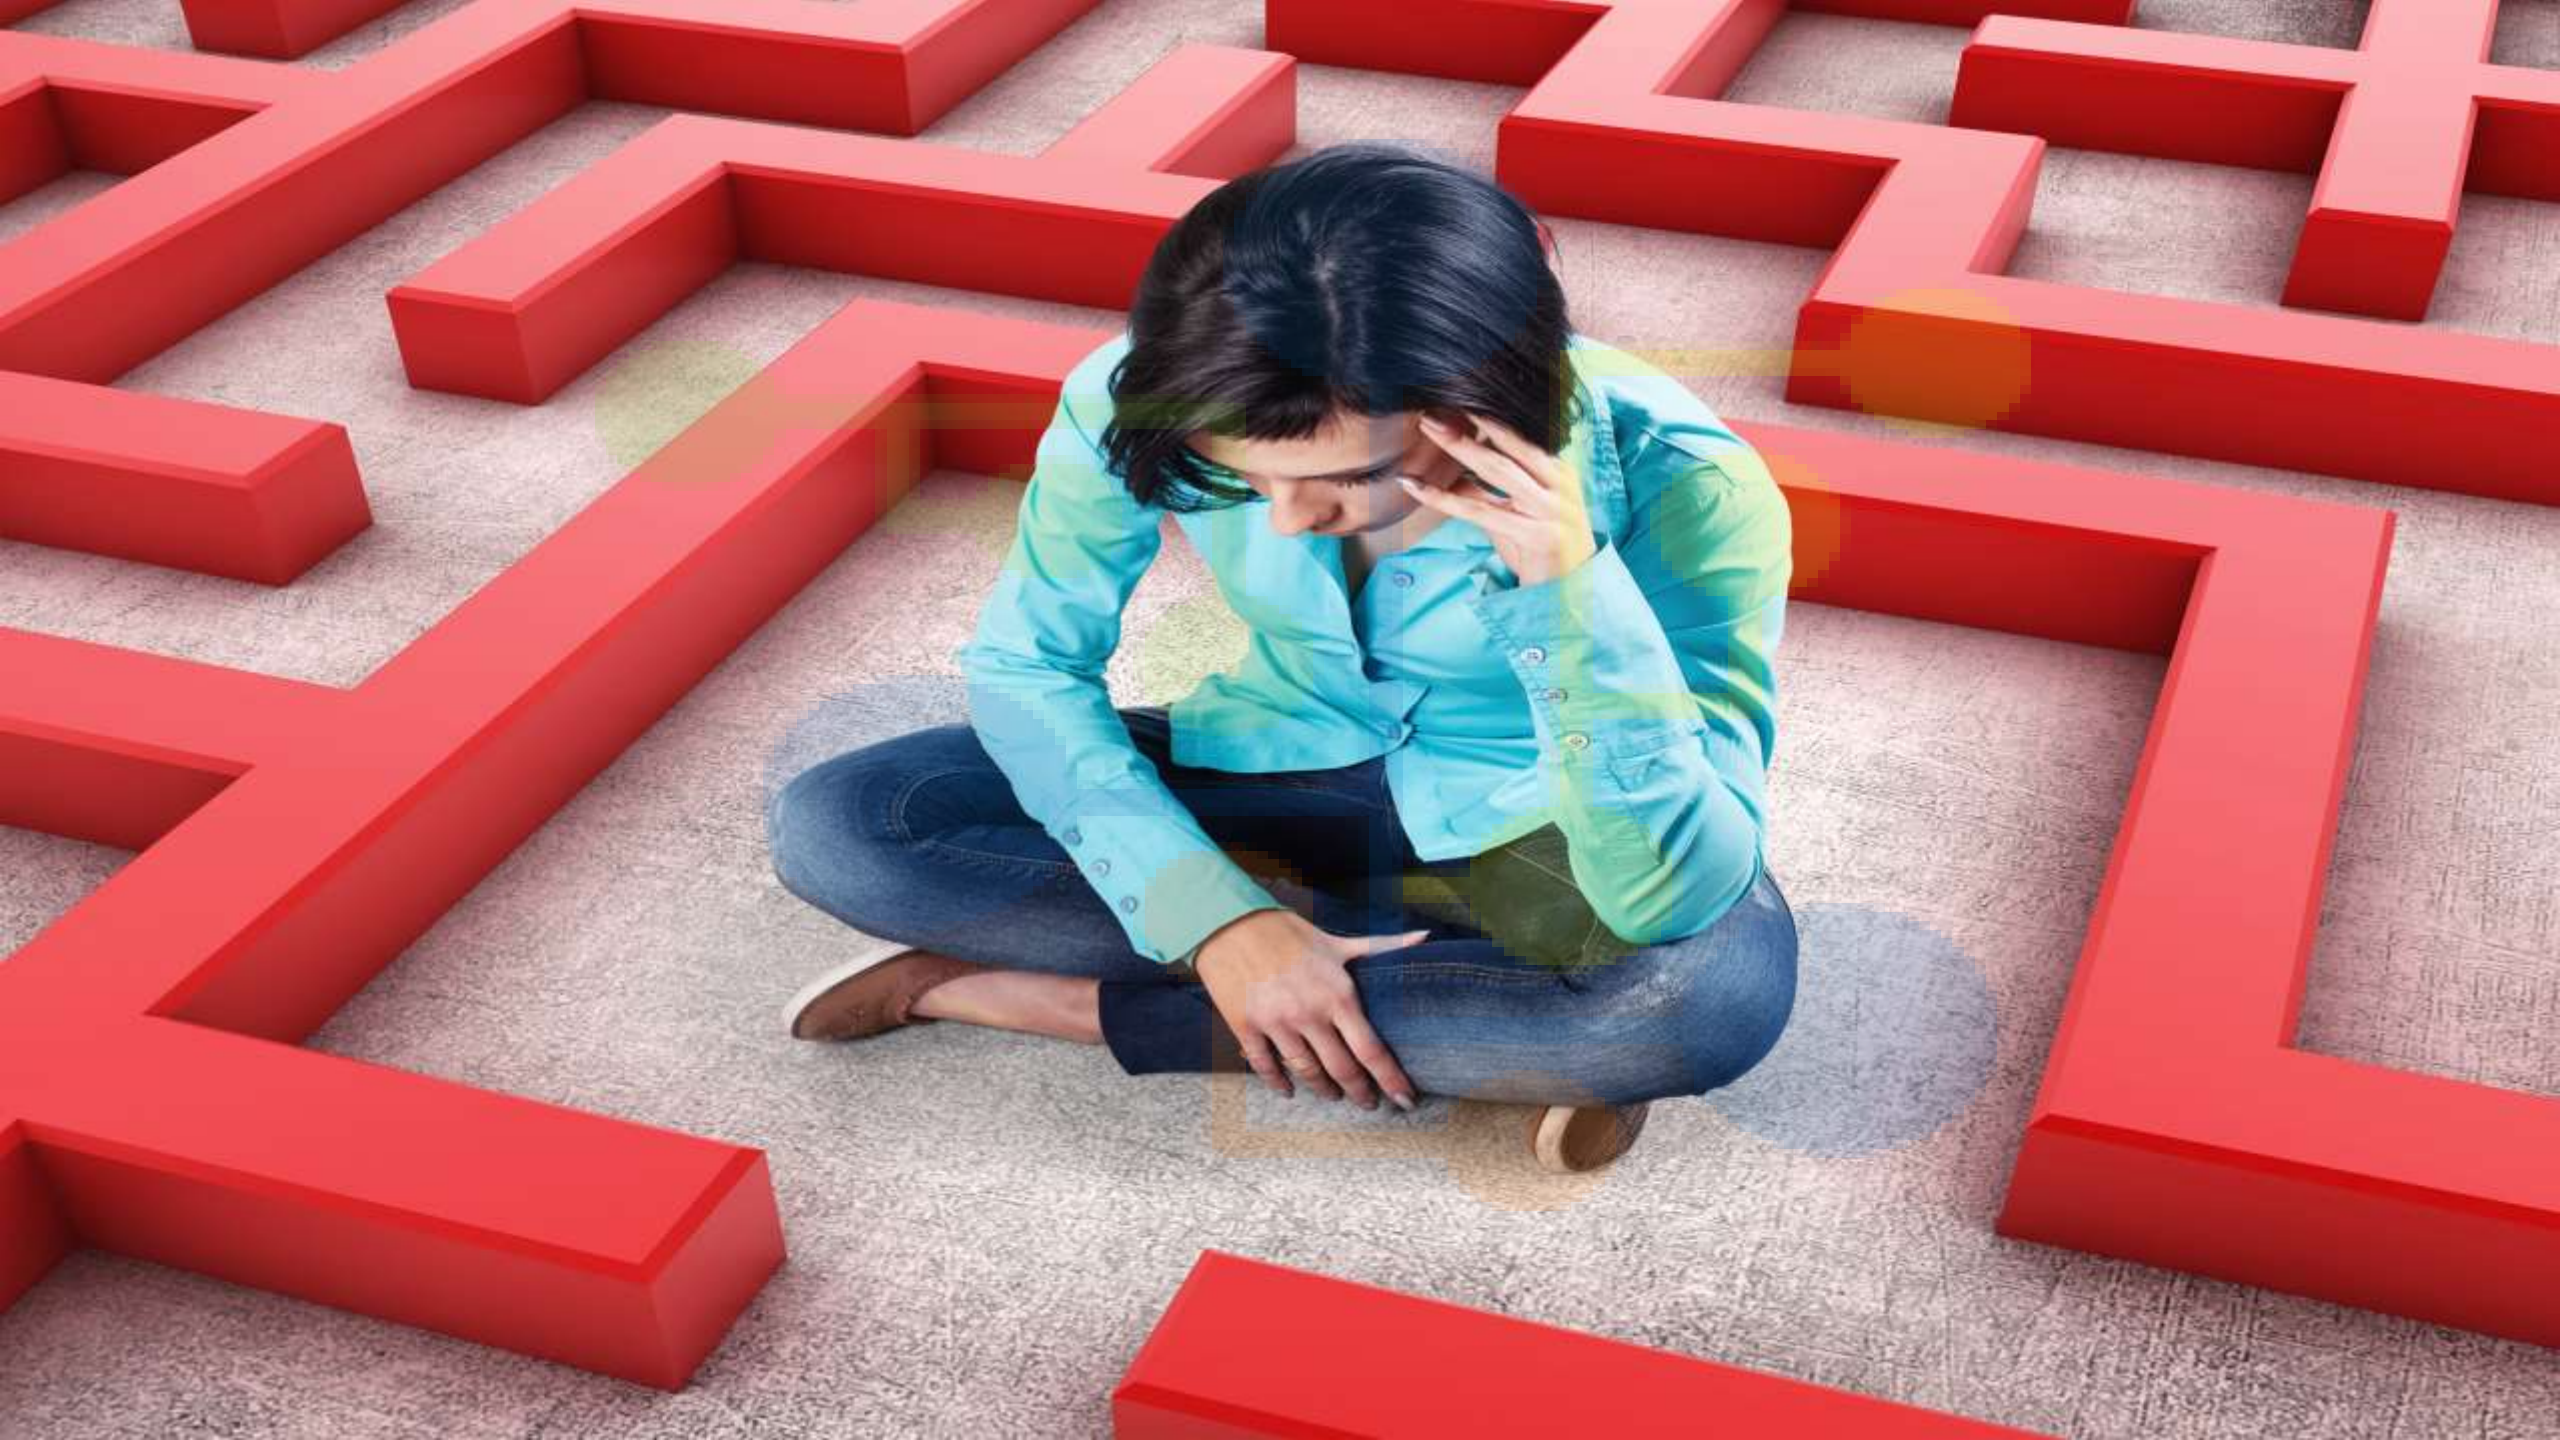

Apache Spark e Big Data

Como armazenar e processar todos esses dados, se o volume aumenta de forma exponencial?

Apache Spark e Big Data

Clusters são conjuntos de computadores (servidores) conectados, que executam como se fossem um único sistema.

Apache Spark e Big Data

O Apache Spark é um sistema de análise de dados distribuído e altamente escalável. Permite processamento em memória e o desenvolvimento de aplicações em Java, Scala e Python, assim como a linguagem R.

O Apache Spark extende as funcionlidades do MapReduce, suportando tarefas mais eficientes, como querys interativas e processamento de streaming de dados. Uma de suas principais características é a velocidade, por permitir o processamento de dados em memória. É bastante eficiente no processamento de dados em disco.

Apache Spark e Big Data

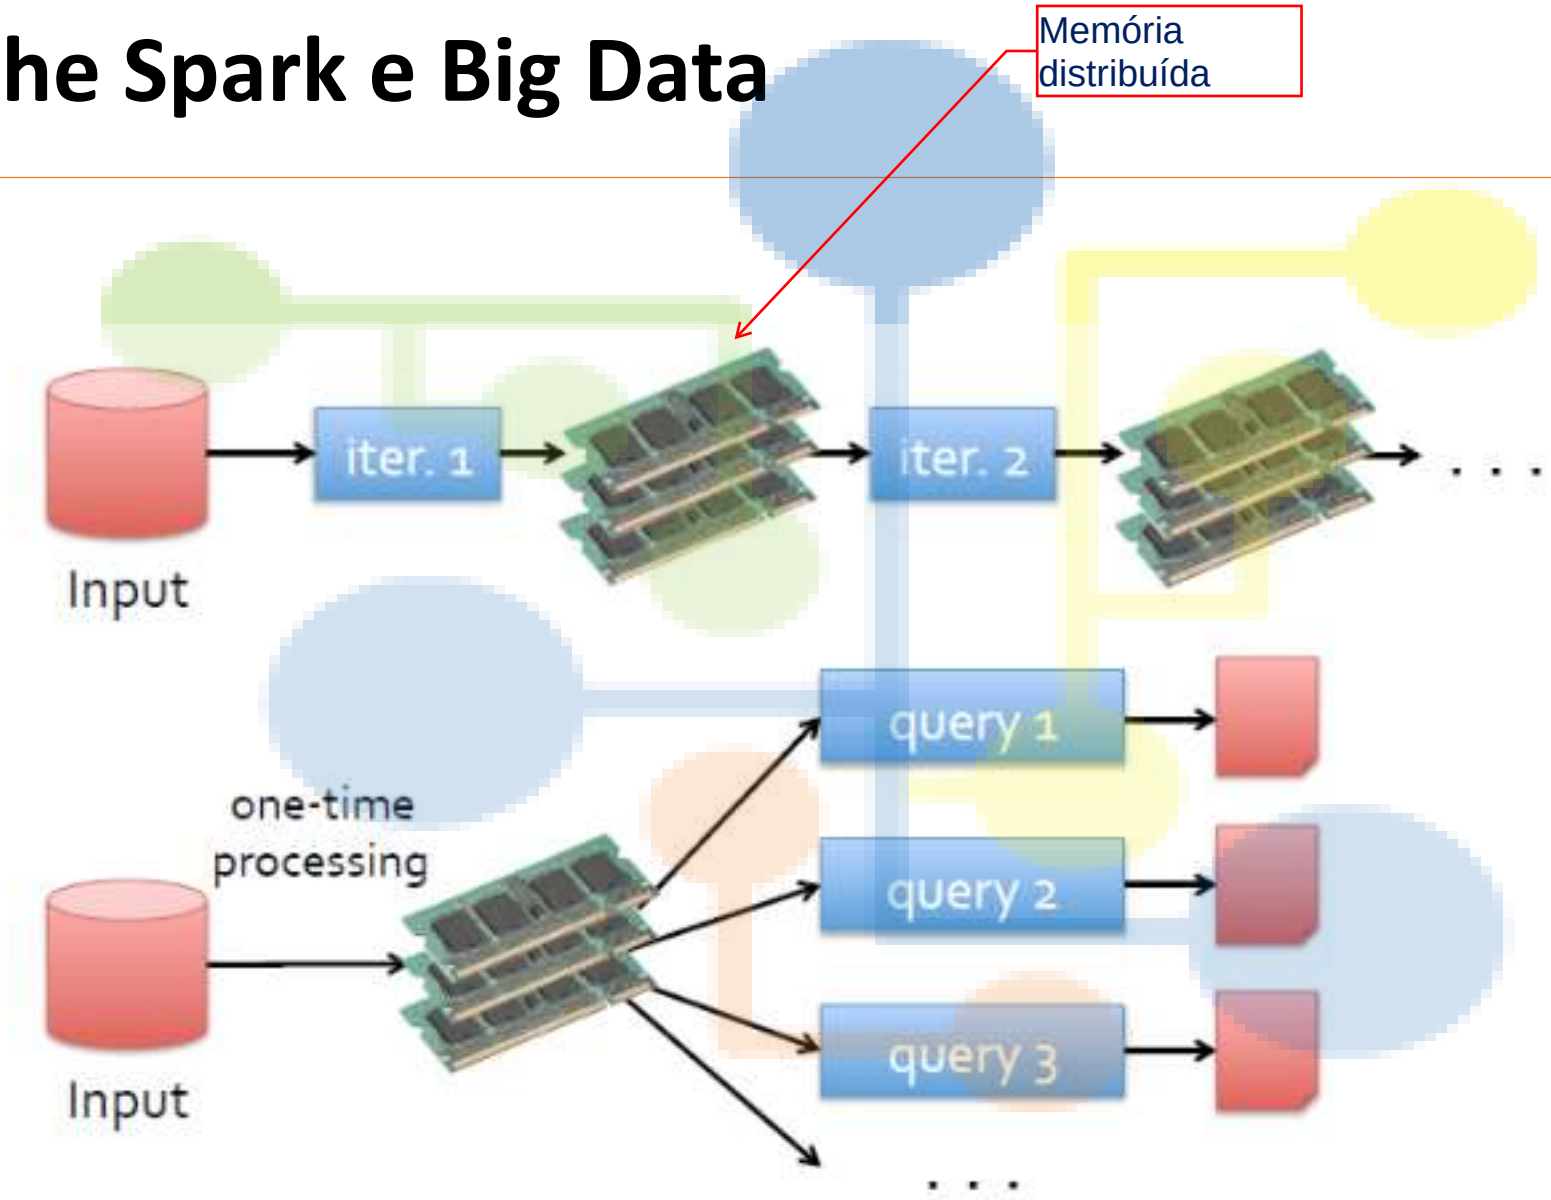

Apache Spark e Big Data

Apache Spark é um framework open-source para processamento de Big Data construído para ser veloz, fácil de usar e para análises sofisticadas.

Apache Spark e Big Data

Apache Spark é uma ferramenta de análise de Big Data, escalável e eficiente.

Apache Spark e Big Data

O Spark é desenvolvido em linguagem Scala e executado em JVM

Scala

Ecossistema e Componentes do Apache Spark

Ecossistema e Componentes do Apache Spark

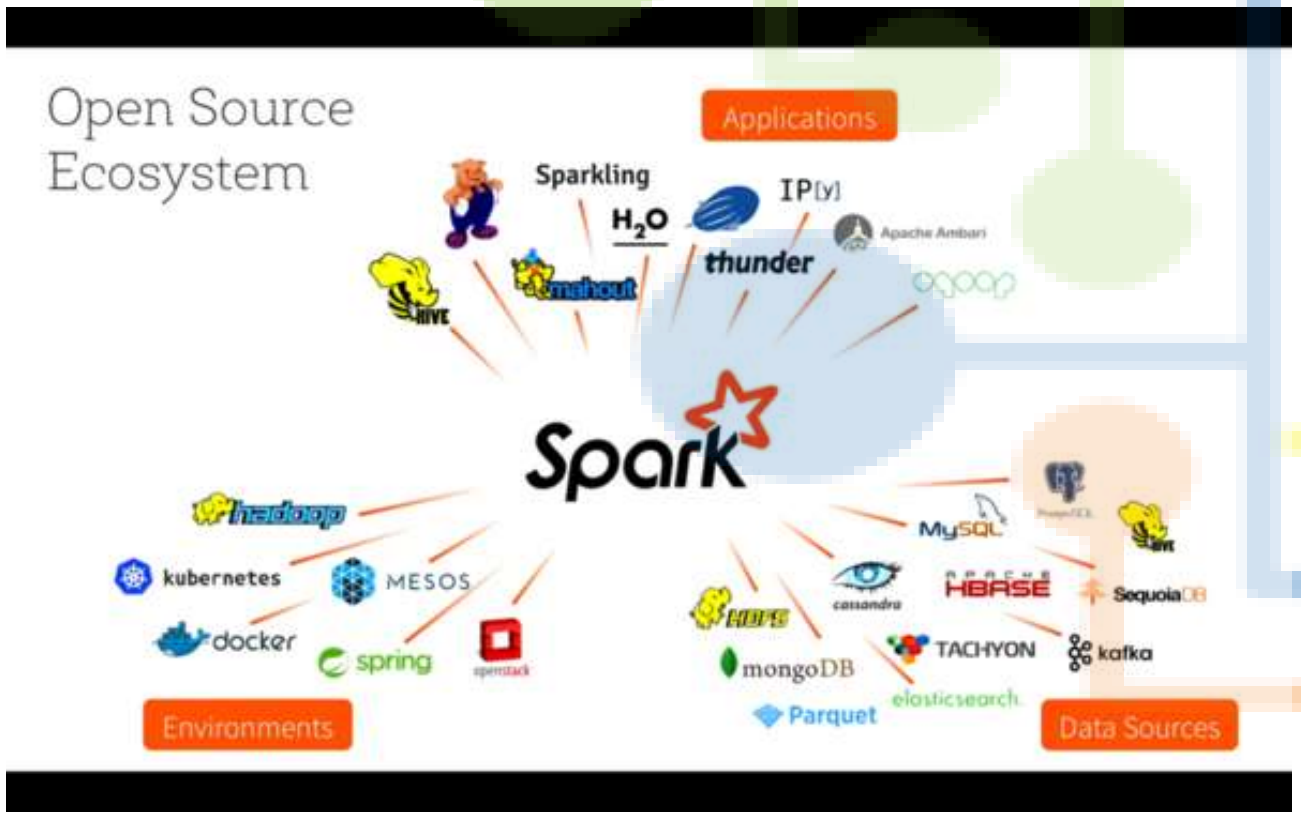

Ecossistema Spark

Ecossistema e Componentes do Apache Spark

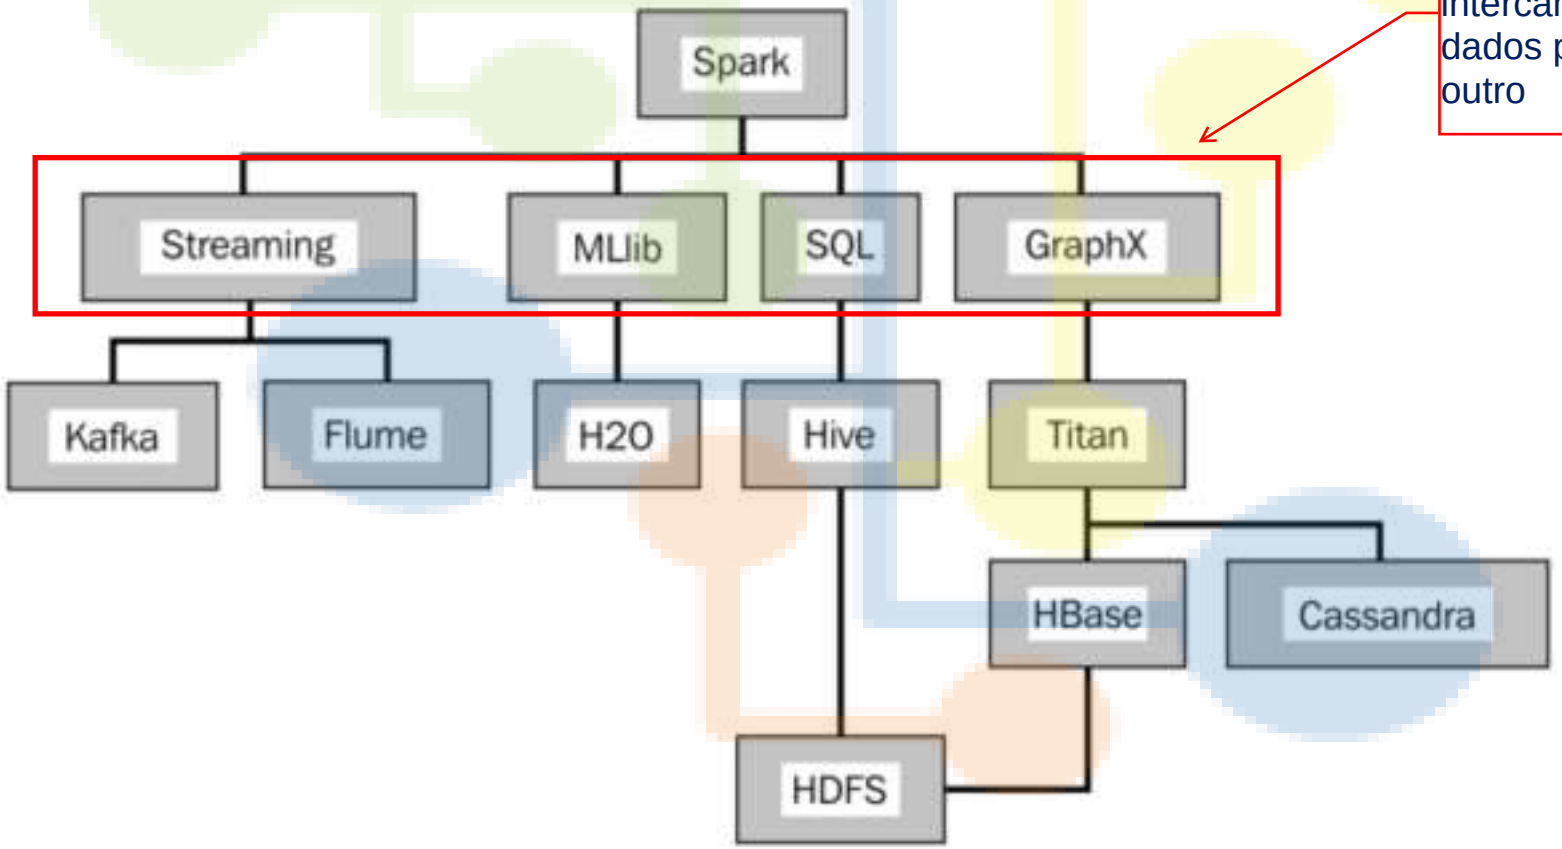

4 módulos principais do Spark. Estes módulos são intercambiáveis, ou seja, os dados podem fluir de um para outro

Ecossistema e Componentes do Apache Spark

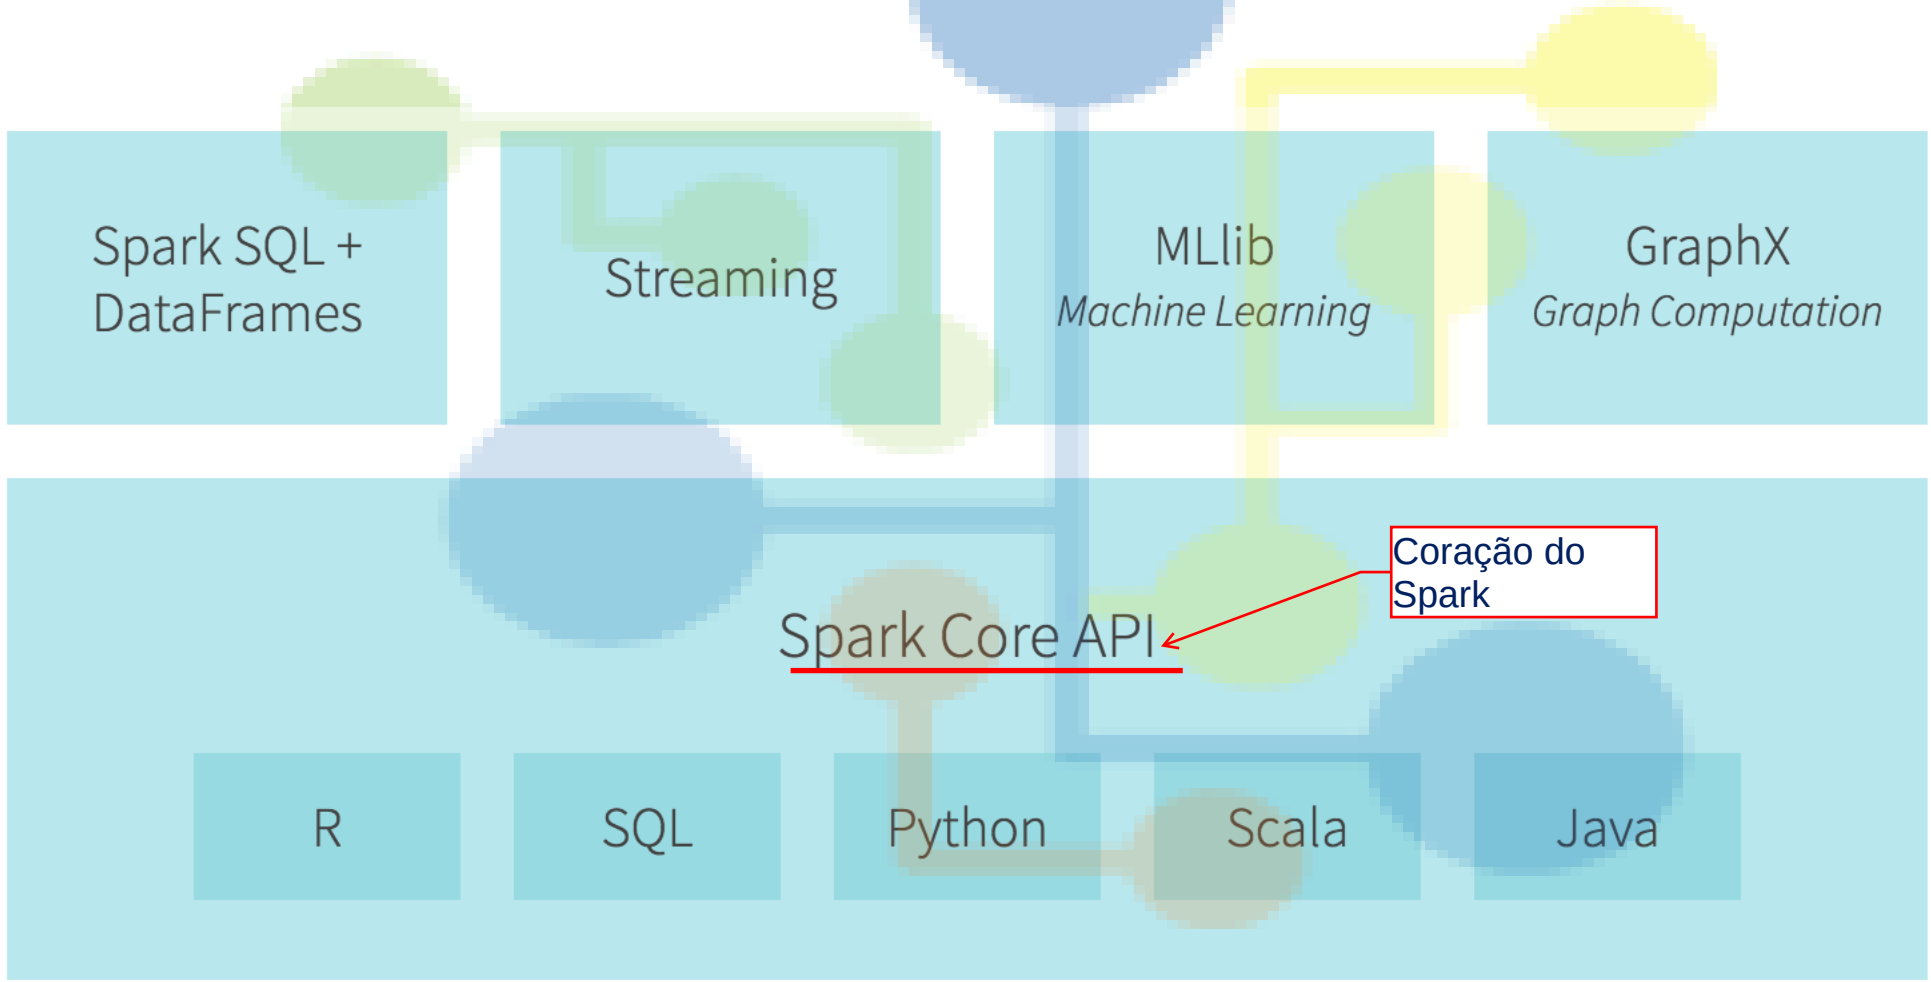

Ecossistema e Componentes do Apache Spark

Spark Streaming: processa dados em tempo real e realiza operações como transformações, controle de persistência, checkpoint etc.

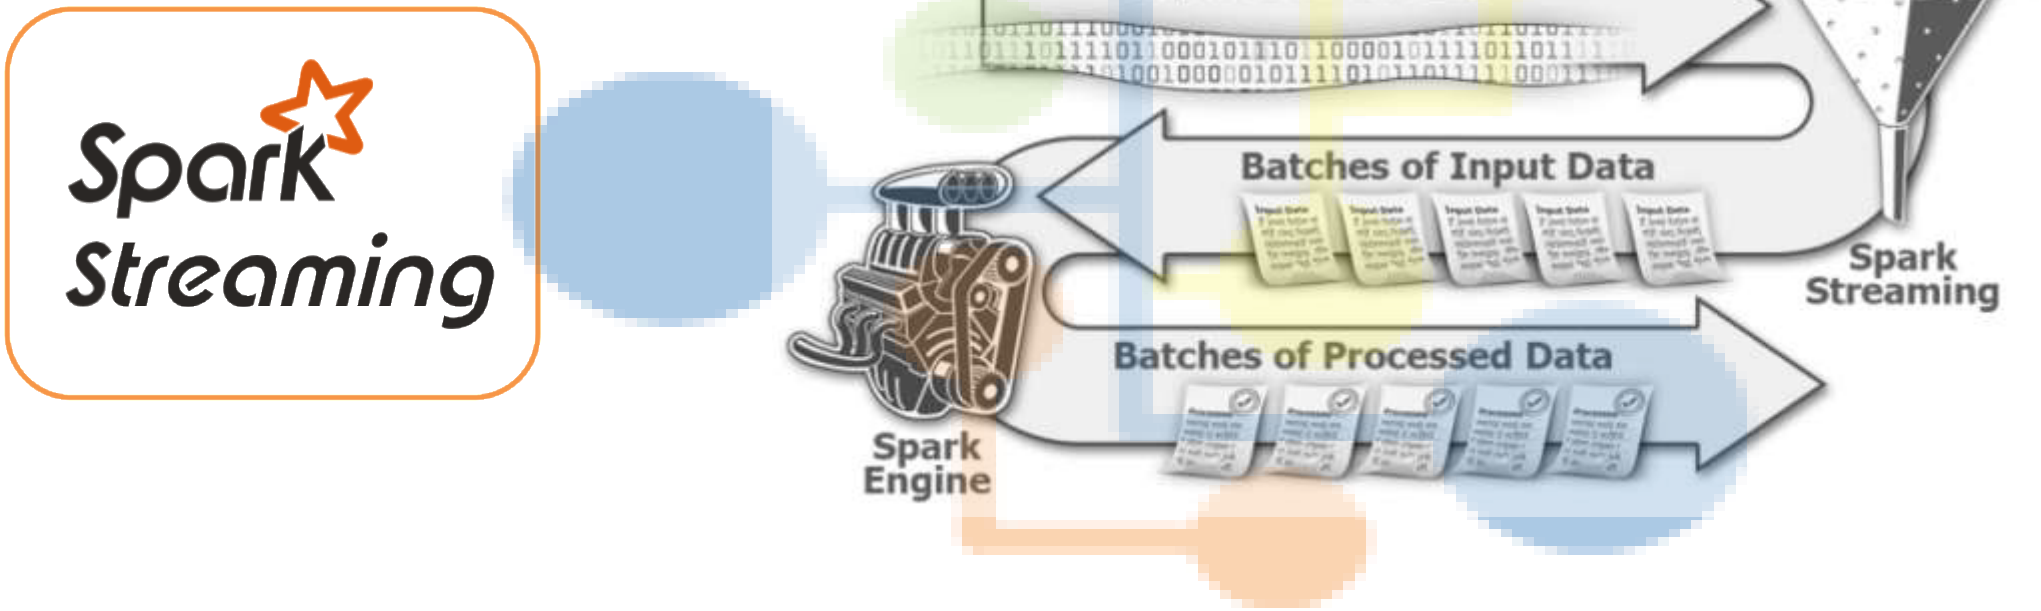

Ecossistema e Componentes do Apache Spark

O Spark Streaming pode ser usada para processar dados em tempo real baseado na computação de microbatch, para isso é utilizado o DStream, que é uma série de RDD's ao longo do tempo.

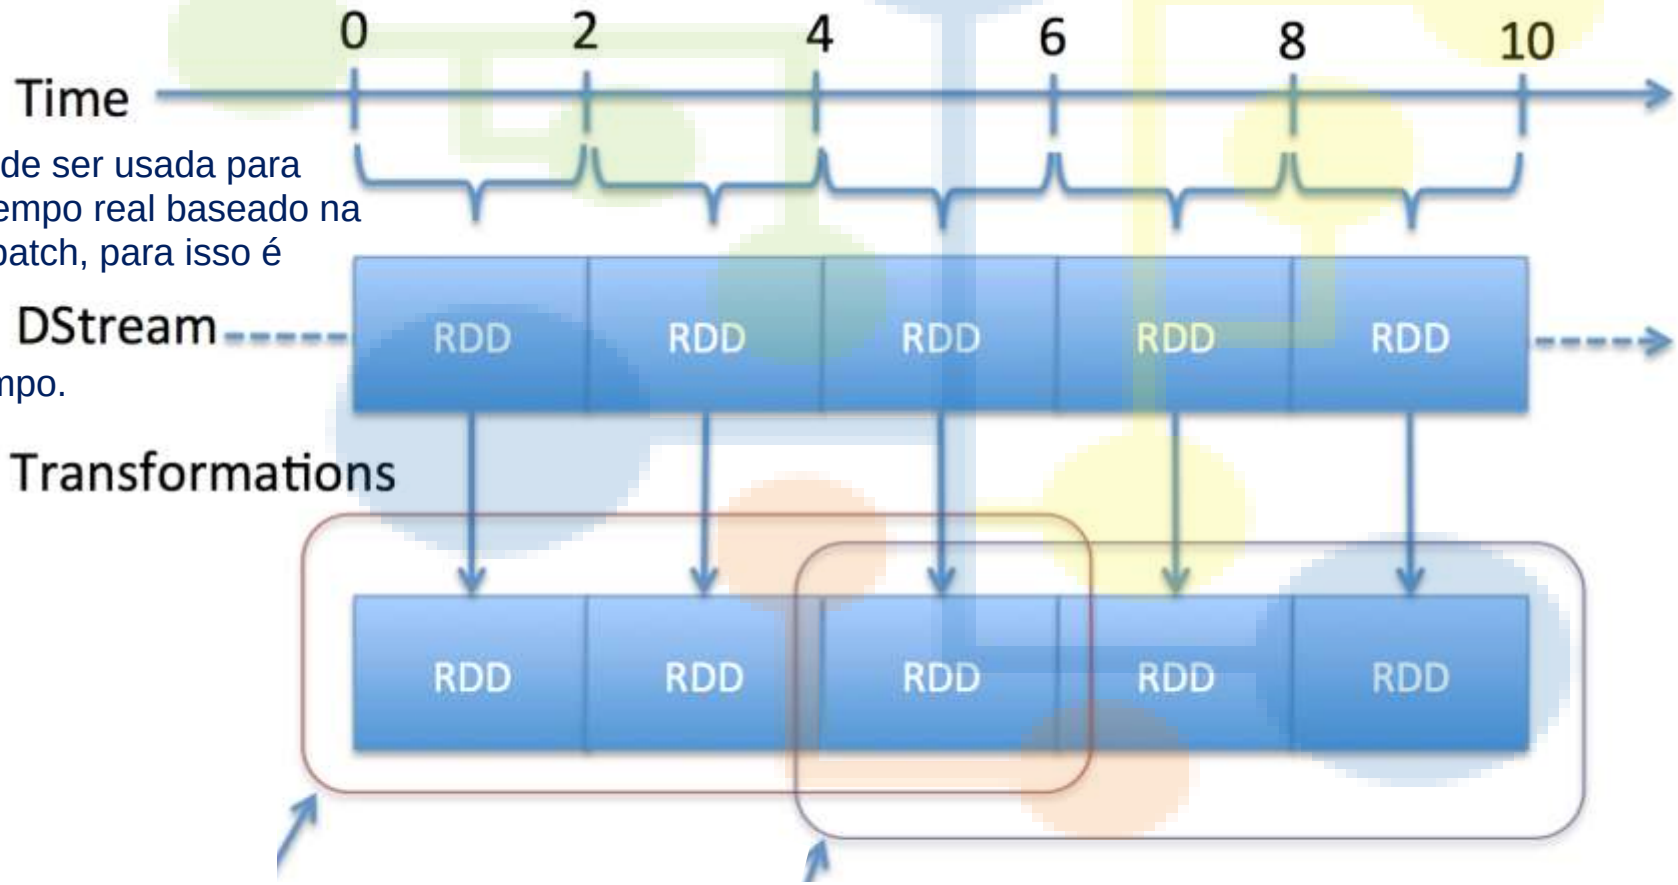

Ecossistema e Componentes do Apache Spark

Ecossistema e Componentes do Apache Spark

Para processamento de dados estruturados

Ecossistema e Componentes do Apache Spark

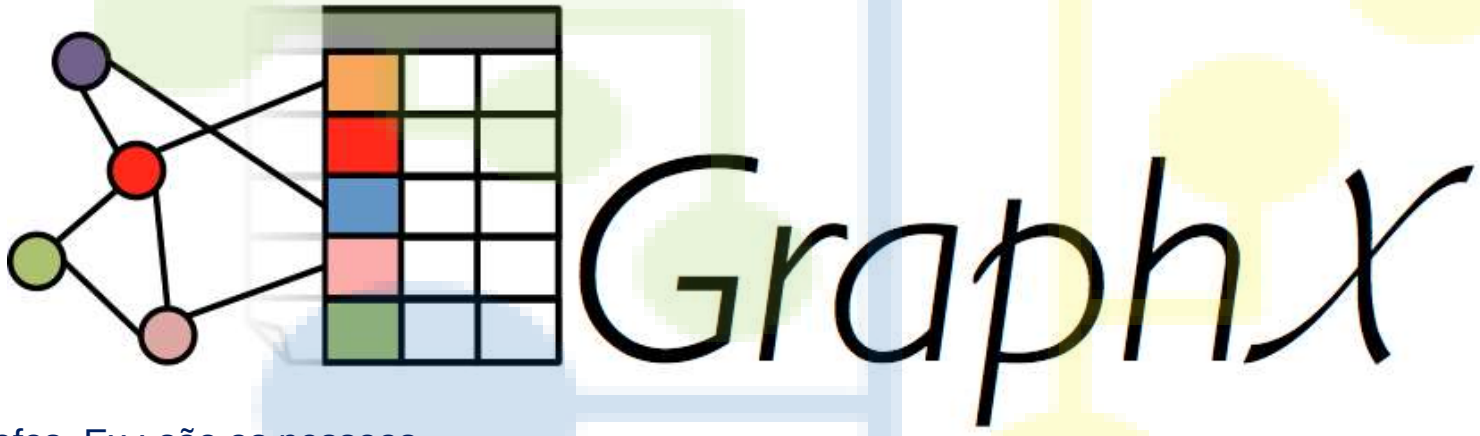

Para processamento grafos. Ex.: são as pessoas conectadas no FB.

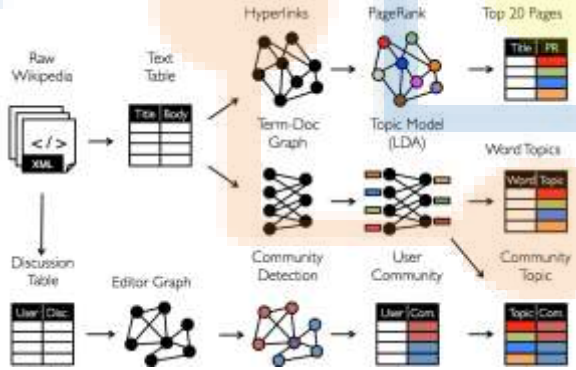

Ecossistema e Componentes do Apache Spark

Empresa criada pelos desenvolvedores do Spark

Ecossistema e Componentes do Apache Spark

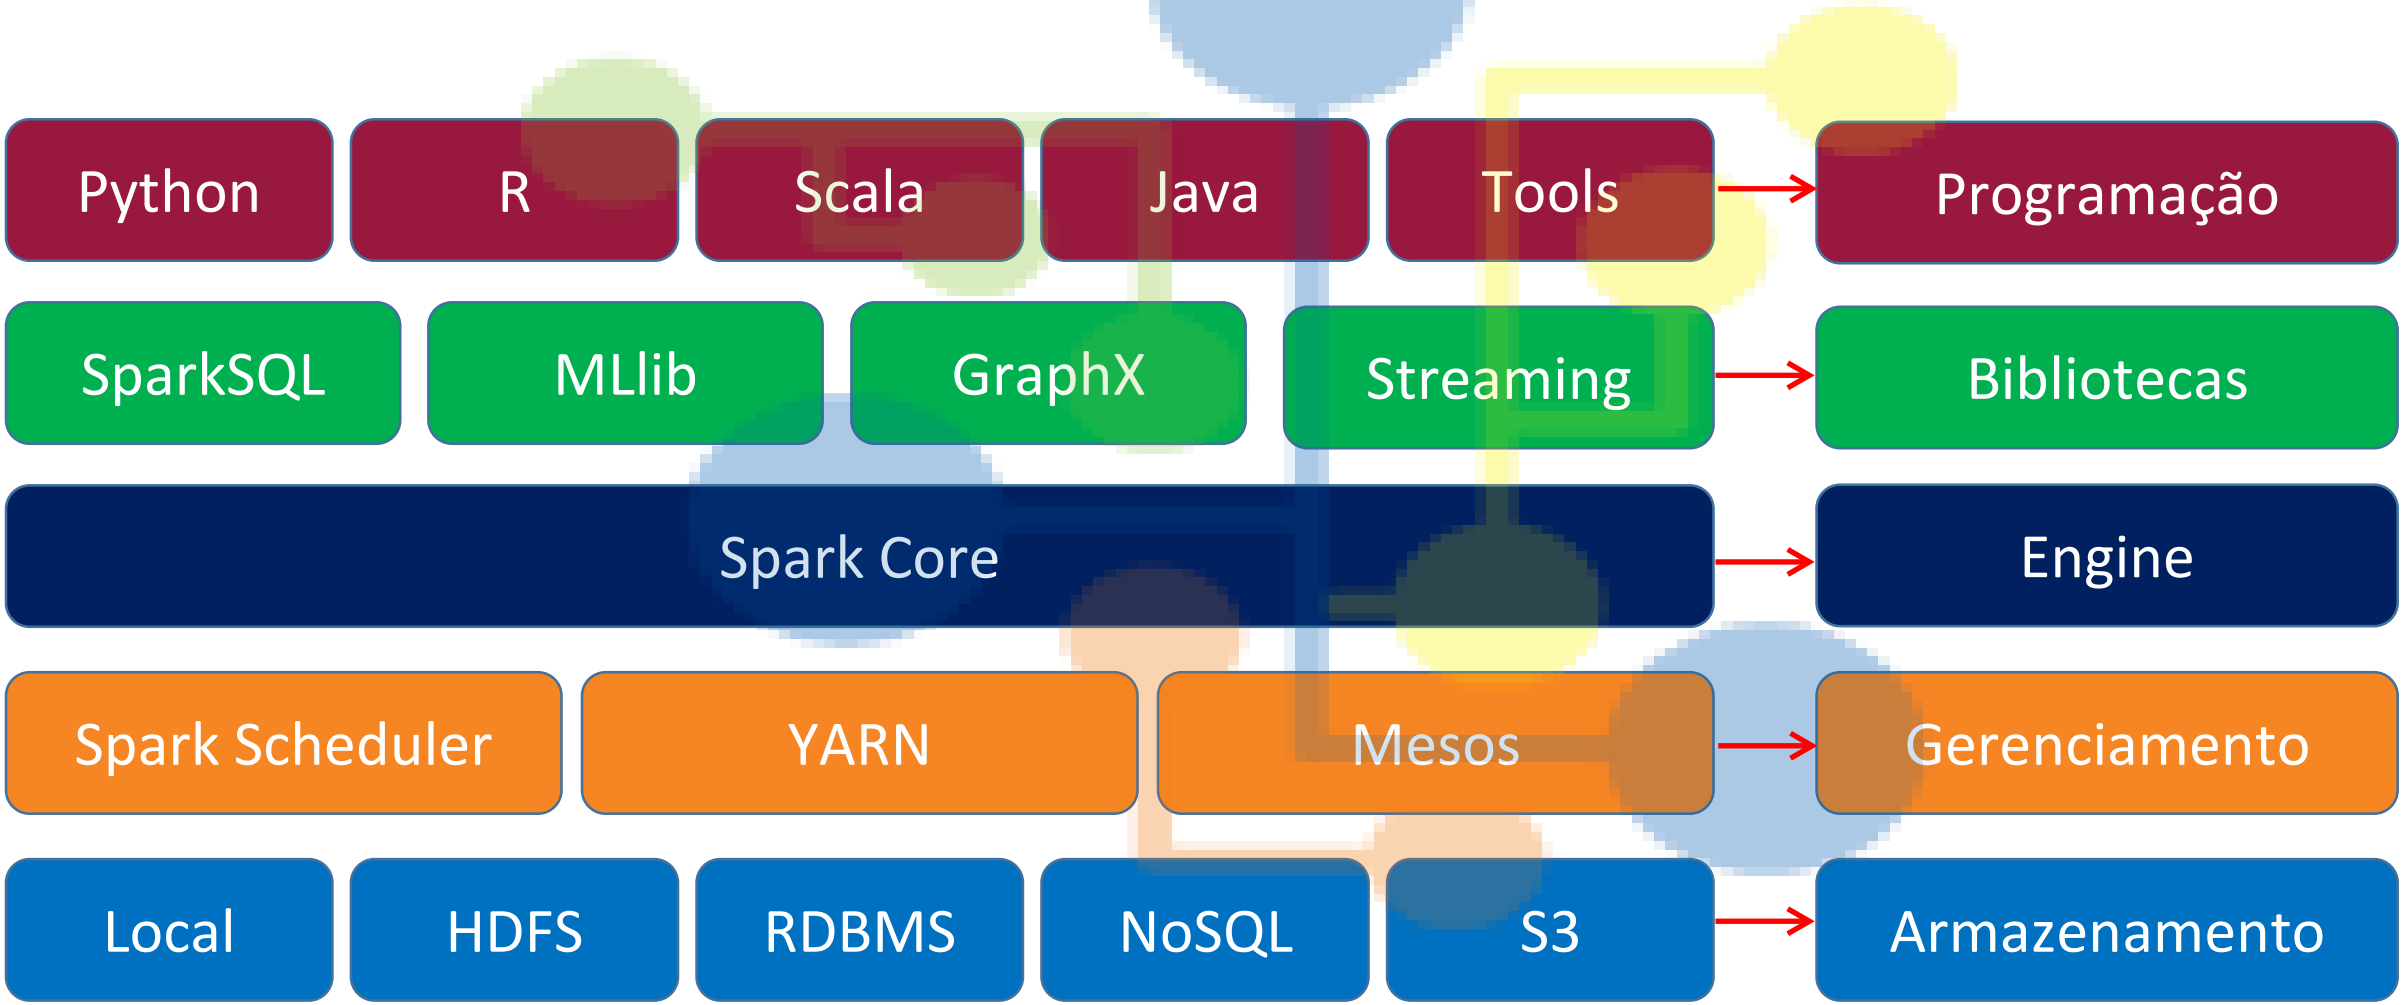

Ecossistema e Componentes do Apache Spark

Quando Devemos Usar o Spark?

Ecossistema e Componentes do Apache Spark

A partir de um banco de dados por exemplo

Quando Devemos Usar o Spark?

- Integração de Dados e ETL
- Análises Interativas Executar querys via terminal
- Computação em Batch de Alta Performance
- Análises Avançadas de Machine Learning MLlib
- Processamento de Dados em Tempo Real Com Spark Streaming

Principais Características do Apache Spark

Principais Características do Apache Spark

Indicado para volume de dados monstruoso

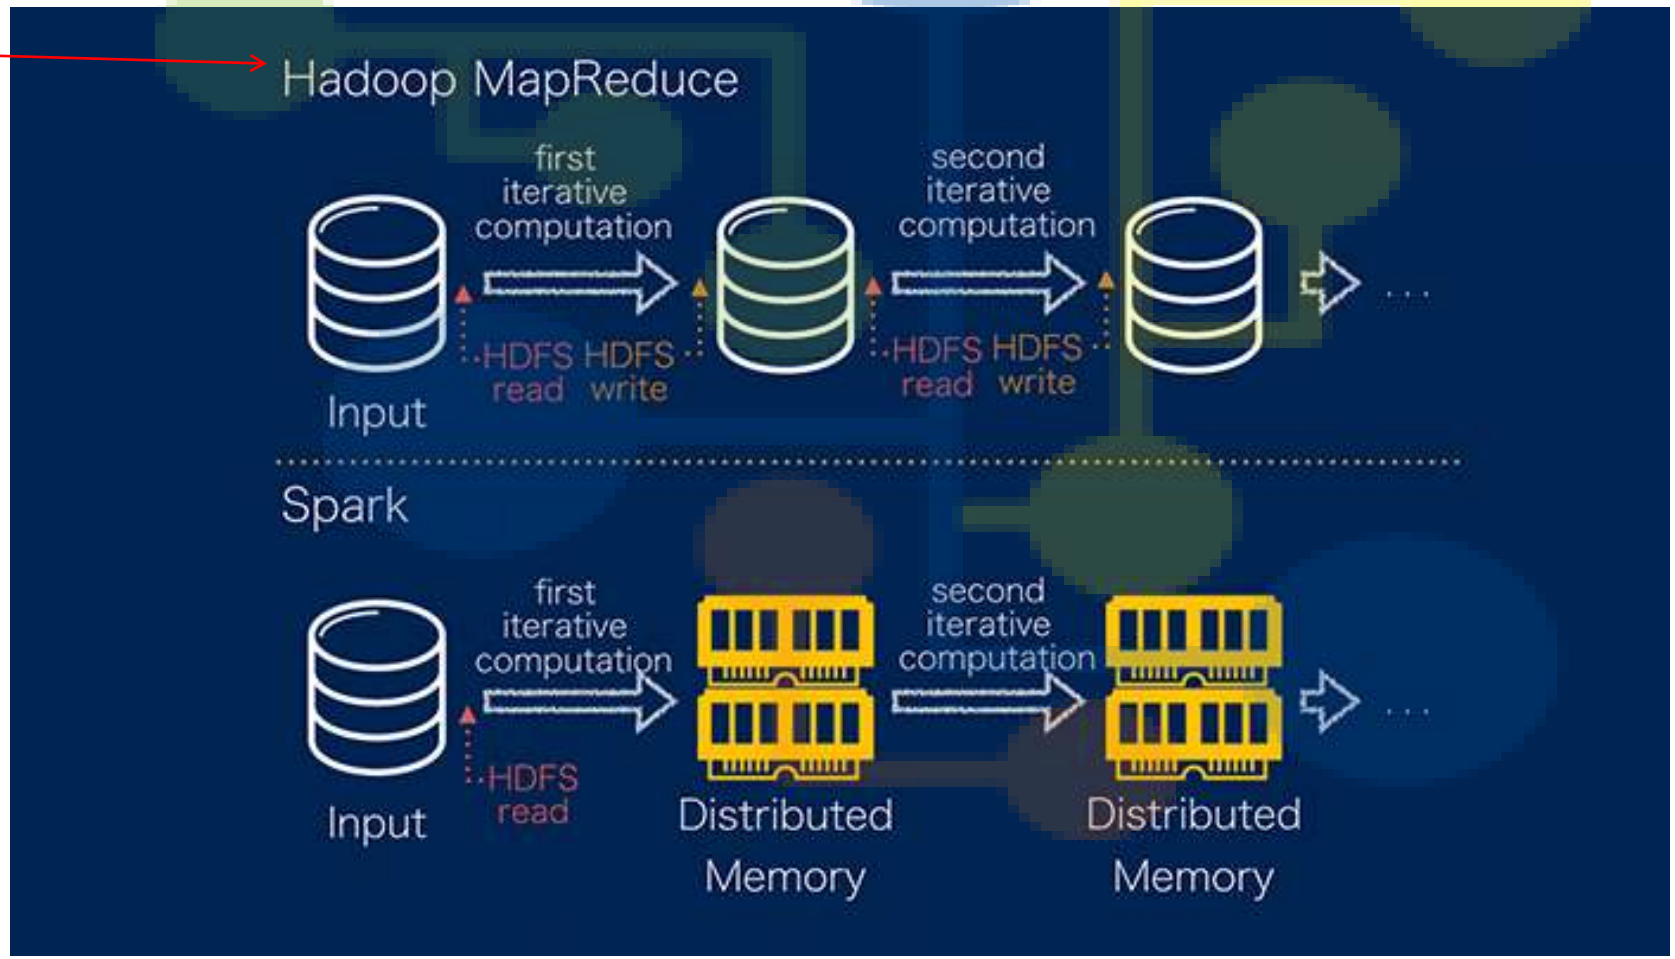

Principais Características do Apache Spark

- Spark realiza operações de MapReduce (MapReduce é paradigma de programação: mapeia e reduz).
- Spark pode utilizar o HDFS mas existem outras opções de armazenamento
- Spark permite construir um workflow de Analytics
- Spark utiliza a memória do computador de forma diferente e eficiente
- Spark é veloz
- Spark é flexível
- Spark é gratuito

Hadoop MapReduce
x
Apache Spark

Hadoop MapReduce
x
Apache Spark

Hadoop MapReduce e Apache Spark são os dois frameworks mais populares para computação em cluster e análise de dados de larga escala (Big Data).

Hadoop MapReduce
x
Apache Spark

Estes dois frameworks escondem a complexidade existente no tratamento de dados com relação a paralelismo entre tarefas e tolerância a falha por meio da exposição de uma simples API com informações para os usuários.

Hadoop MapReduce x Apache Spark

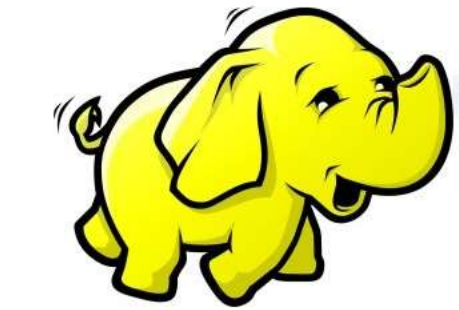

Armazenamento distribuído

Processamento distribuído

Hadoop MapReduce x Apache Spark

Este é o paradigma de mapeamento (buscar padrões) e redução

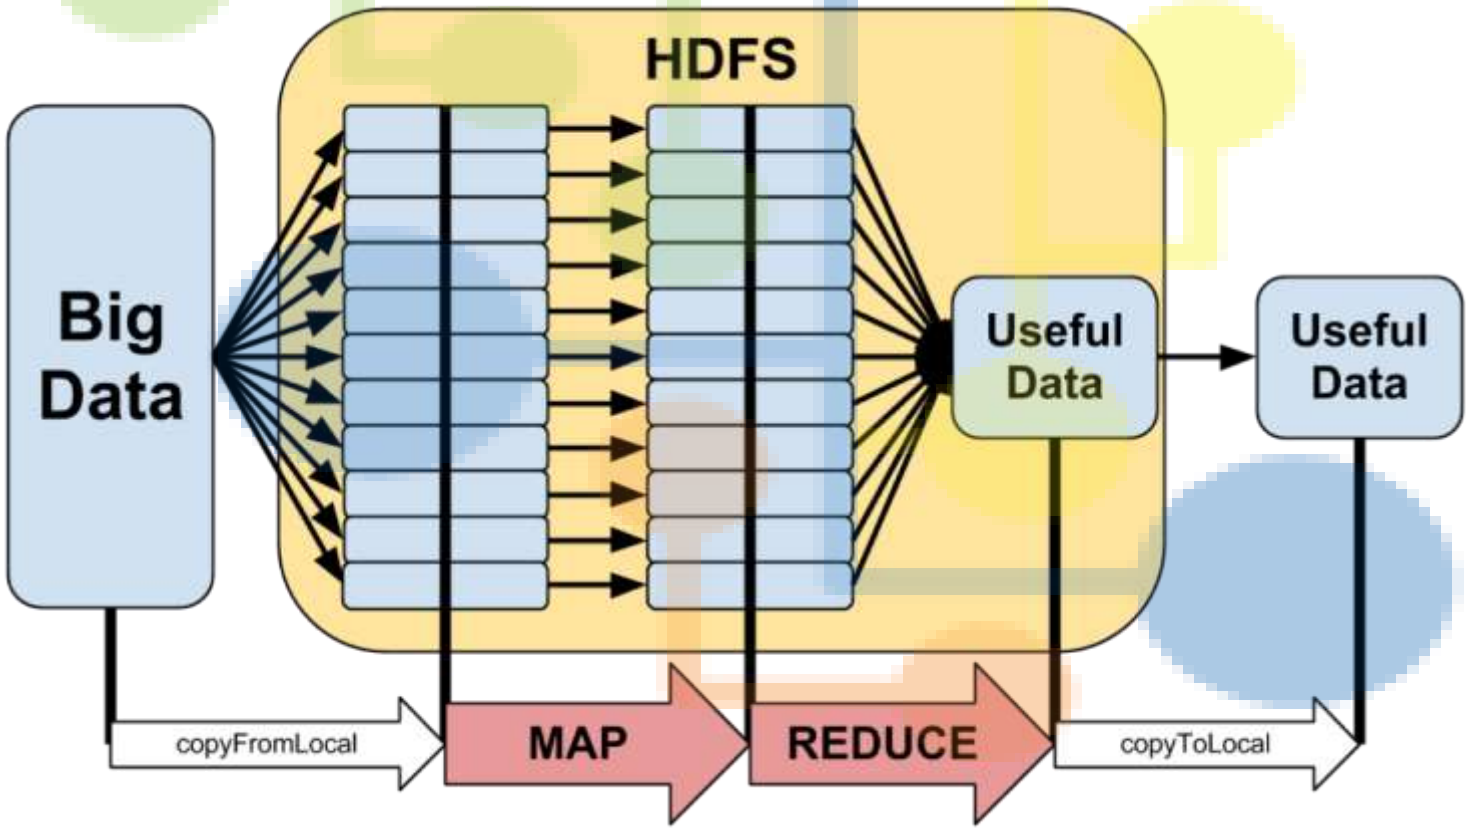

Hadoop MapReduce x Apache Spark

O Spark realiza o processamento distribuído, de forma similar ao Hadoop MapReduce, porém com muito mais velocidade.

Hadoop MapReduce x Apache Spark

O Spark não possui sistema de armazenamento, podendo usar o HDFS como fonte/destino de dados.

O Processo de MapReduce no Apache Spark

Operações de map, alimentados com big data

Operações de reduce

O shuffle une os fragmentos de dados que possuem alguma similaridade e alimenta o processo de redução, assim, os dados que no início estavam bagunçados passam a ter um padrão

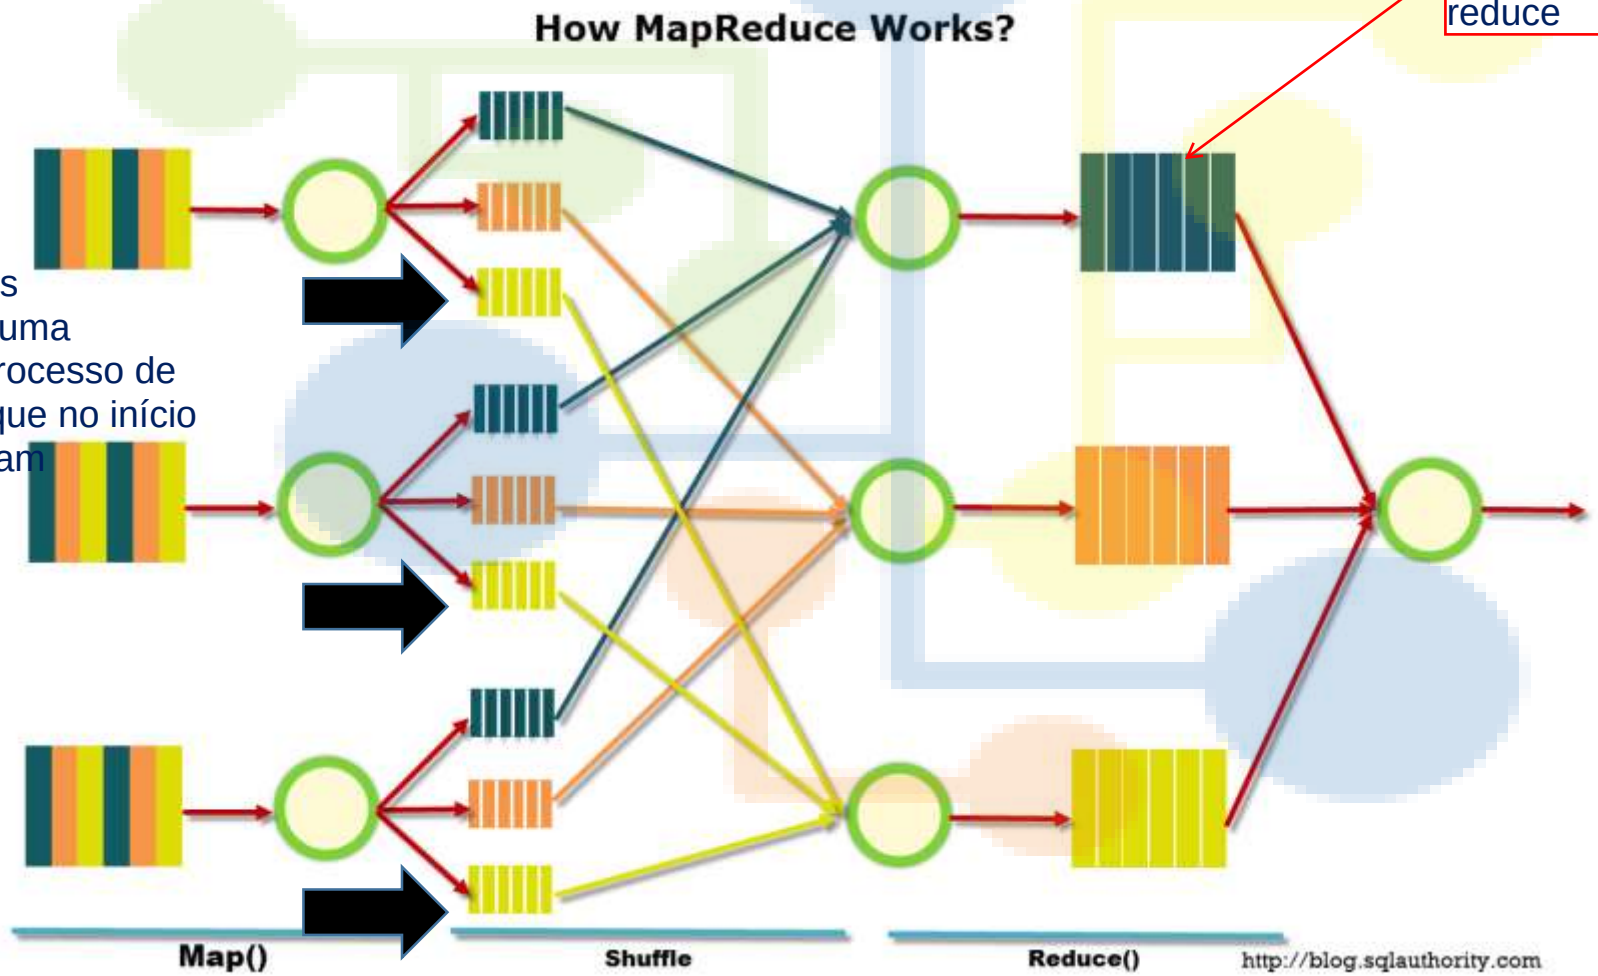

O Processo de MapReduce no Apache Spark

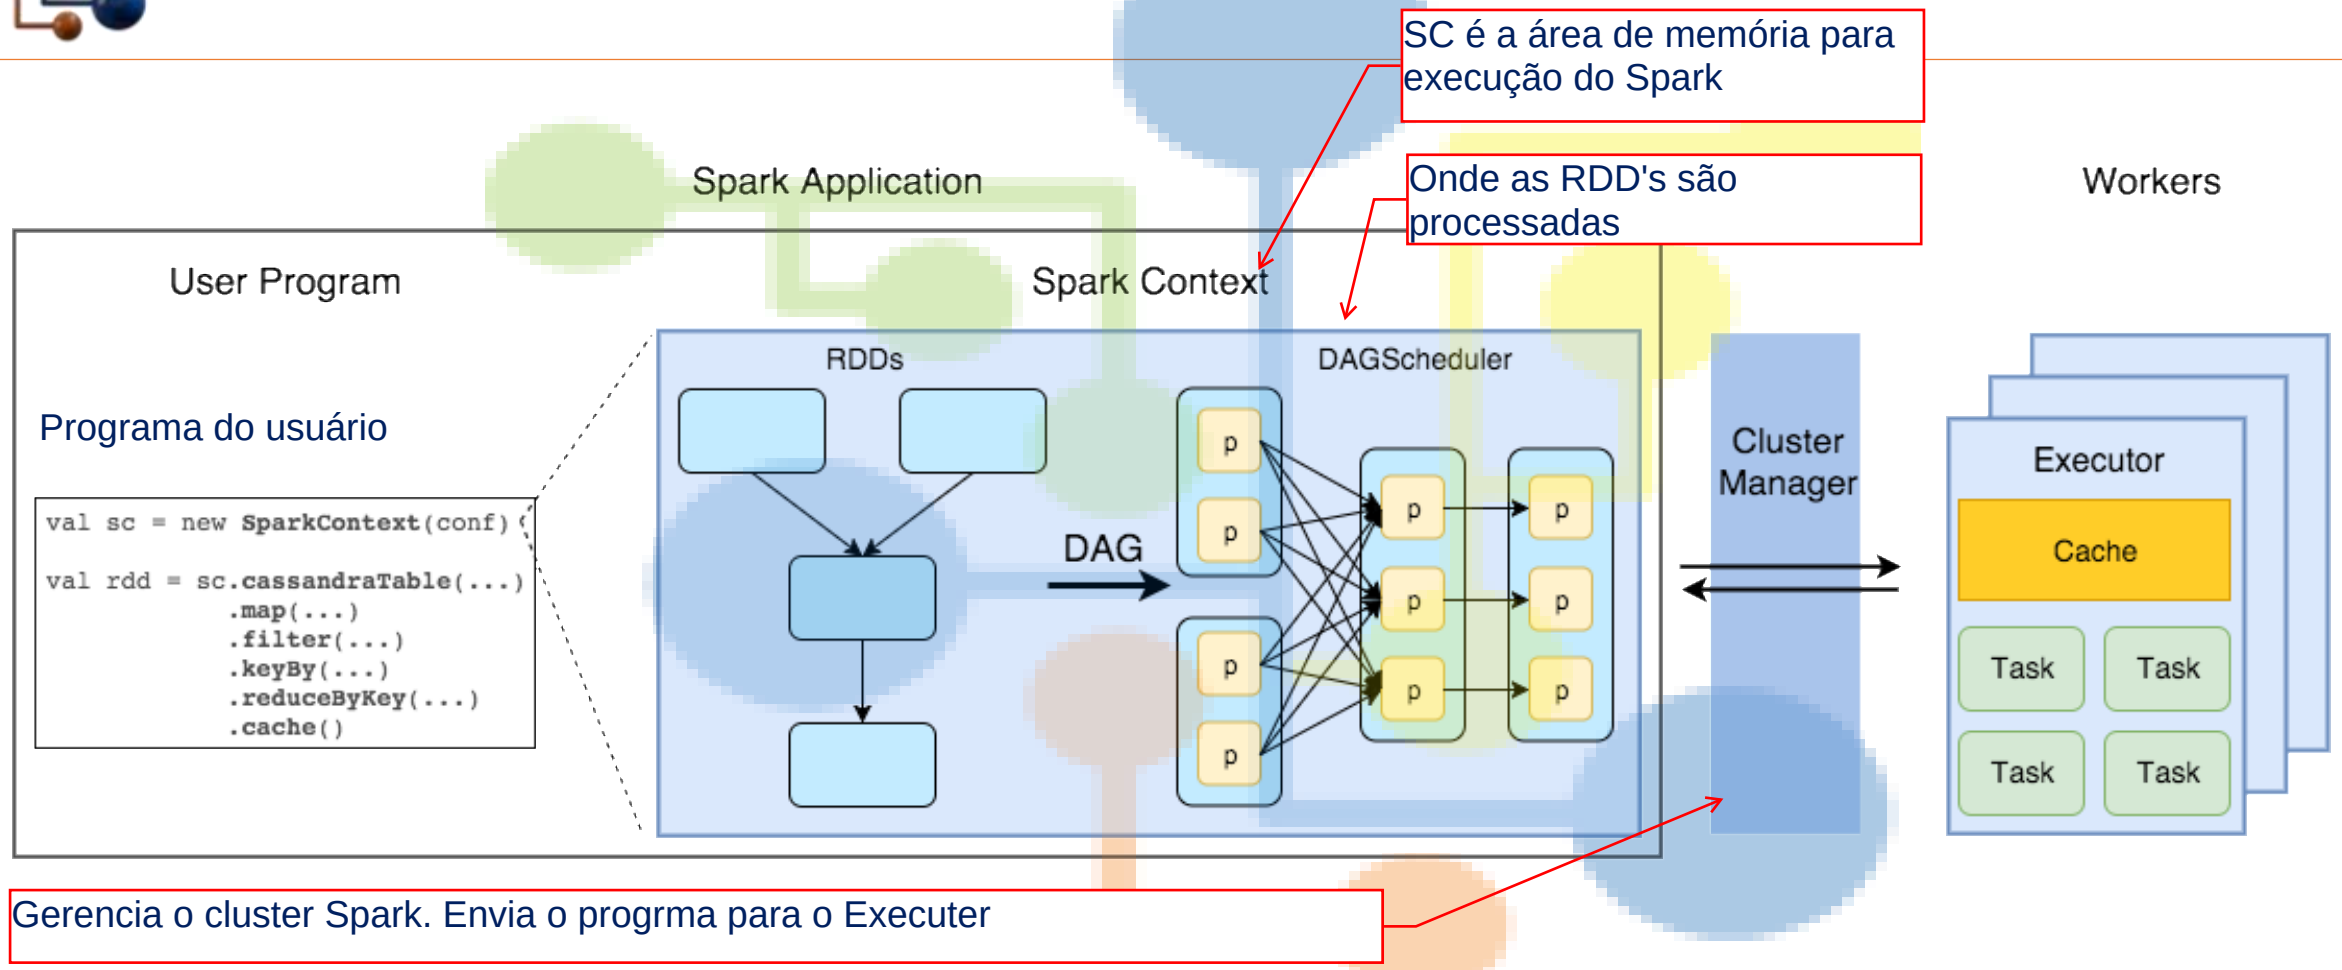

RDD's = Resilient Distributed Datasets

O Processo de MapReduce no Apache Spark

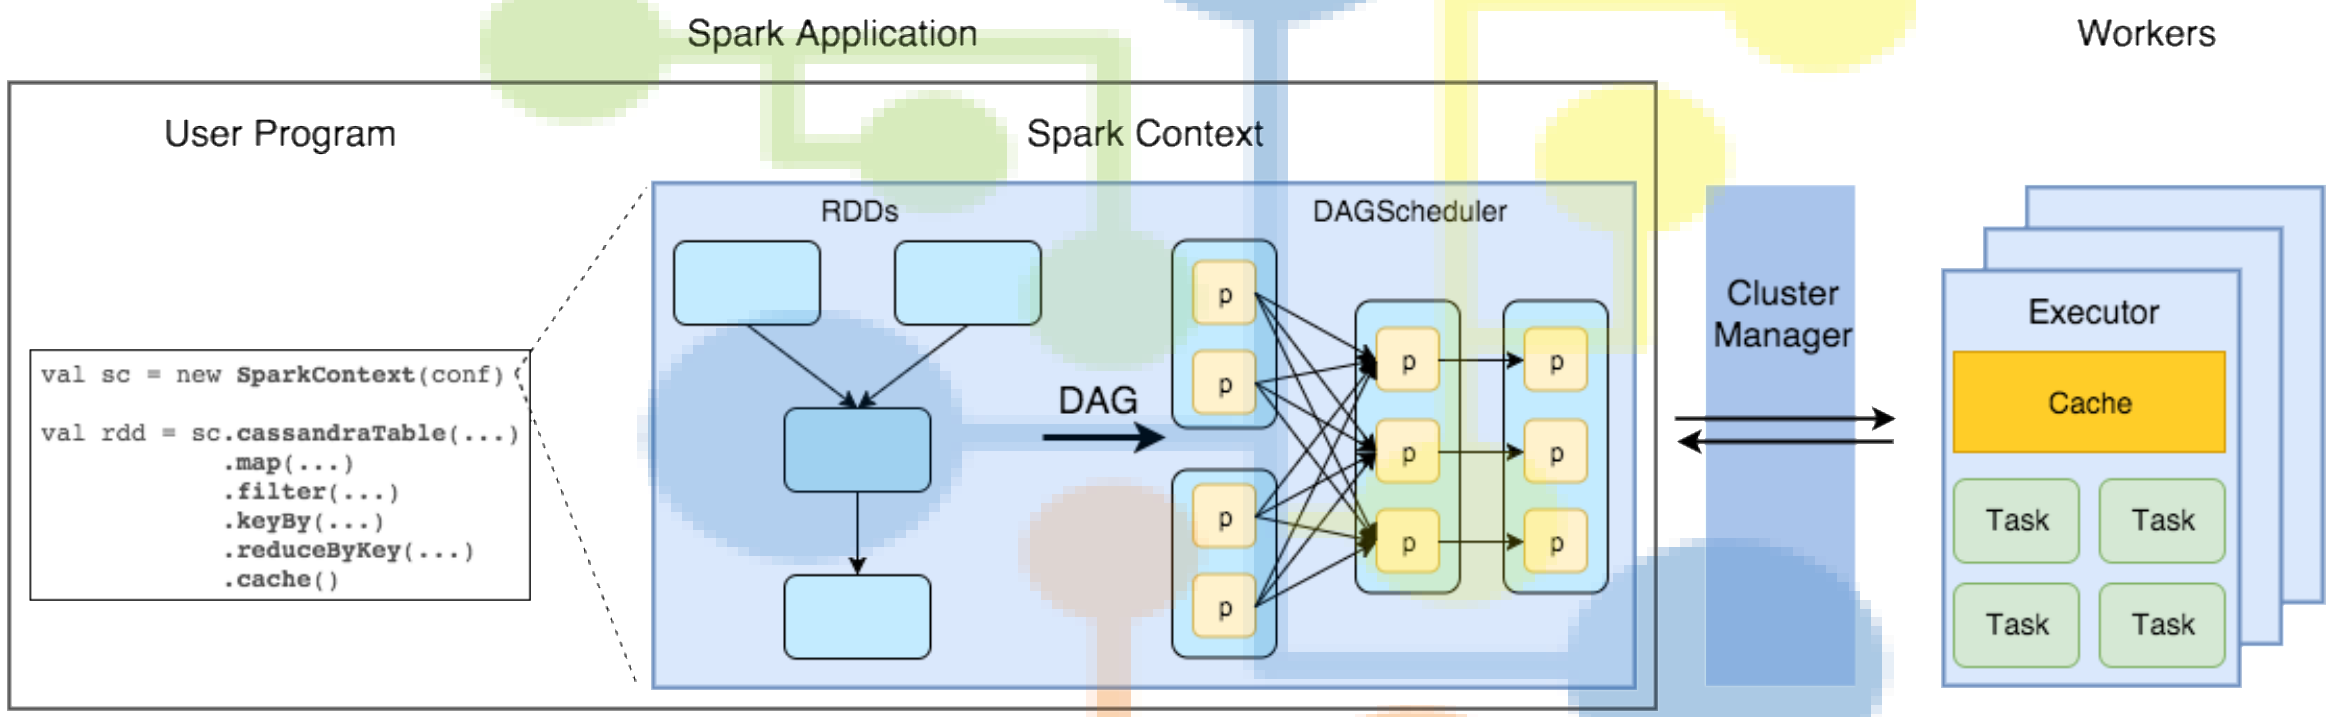

RDD's = Resilient Distributed Datasets

O Processo de MapReduce no Apache Spark

- O Spark suporta mais do que apenas as funções de Map e Reduce.
- Hadoop MapReduce grava os resultados intermediários em disco, enquanto o Spark grava os resultados intermediários em memória, o que é muito mais rápido.
- O Spark fornece APIs concisas e consistentes em Scala, Java e Python (e mais recentemente em R).
- O Spark oferece shell interativo para Scala, Python e R.
- O Spark pode utilizar o HDFS como uma de suas fontes/destinos de dados.

O Processo de MapReduce no Apache Spark

O Cientista de Dados é responsável por definir as regras de manipulação e análise de dados.

O Engenheiro de Dados é responsável por garantir o processamento distribuído, cuidando do pipeline, fontes de dados e destino, bem como pela segurança dos dados.

O Processo de MapReduce no Apache Spark

O Spark e o Hadoop MapReduce tem uma característica principal em comum: são responsáveis por gerenciar o processamento distribuído.

Porém o Spark faz isso de forma muito mais rápida e eficiente que o Hadoop MapReduce.

Profissionais Que Trabalham com Apache Spark

Profissionais Que Trabalham com Apache Spark

Exstem basicamente 3 perfis de profissionais que vão trabalhar com Spark:

- Cientistas de Dados
- Engenheiros de Dados
- Administradores

Anatomia de Uma Aplicação Spark

Anatomia de Uma Aplicação Spark

Cada aplicação Spark inicia uma instância de um Spark Context.

```
val sc = new SparkContext(master="local[*]",
          appName="SparkMe App", new SparkConf)

val lines = sc.textFile(...).cache()

val c = lines.count()
println(s"There are $c lines in $fileName")
```

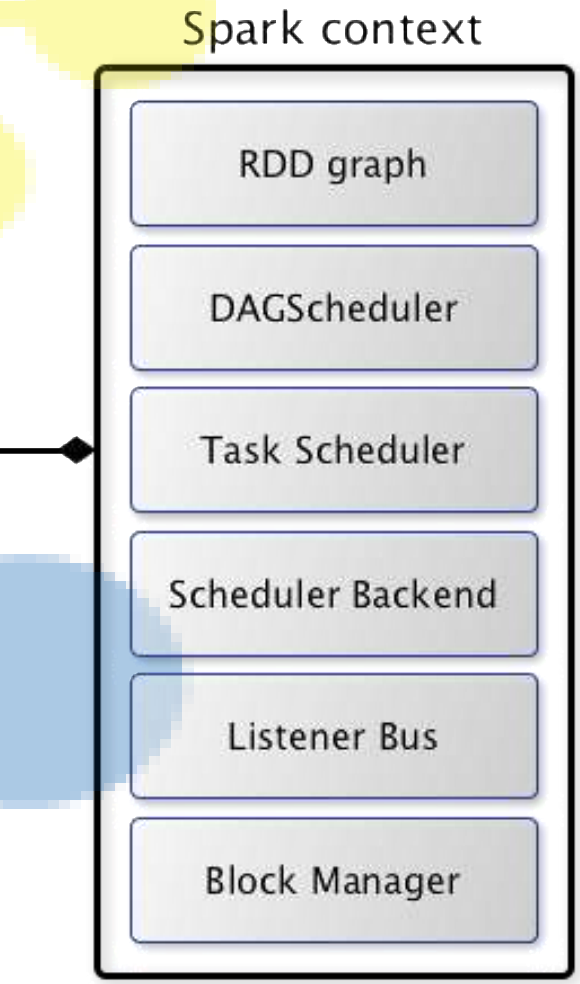

Sem um Spark Context, nada pode ser feito no Spark. Cada aplicação Spark é uma instância de um Spark Context.

Anatomia de Uma Aplicação Spark

O Spark Context é basicamente uma espécie de cliente que estabelece a conexão com o ambiente de execução do Spark e age como o processo principal da sua aplicação.

Anatomia de Uma Aplicação Spark

Com o Spark Context criado, podemos então definir os nossos RDD's e Dataframes, que são os objetos que vão armazenar os dados para o processamento pelo Spark.

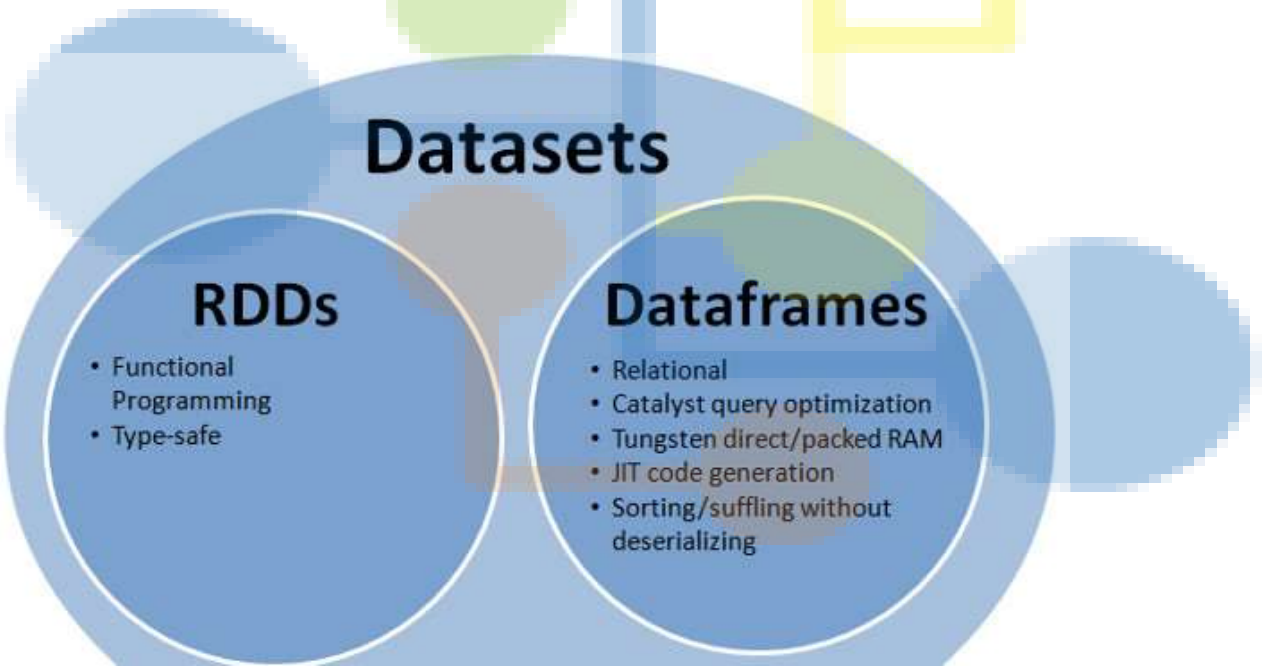

Anatomia de Uma Aplicação Spark

E como criamos um Spark Context?

1. **Shell** – área de trabalho via linha de comando
2. **Spark Context** – conexão ao ambiente Spark criado quando iniciamos o pyspark

Ou seja, uma vez que iniciamos o PySpark, é criado um Spark Context, que nos permite criar RDD's e Dataframes e realizar transformações e ações. Cada operação Spark gera um job que então é executado ou agendado para ser executado ao longo do cluster de computadores ou localmente em nossa máquina.

Anatomia de Uma Aplicação Spark

Quando utilizamos o PySpark e o Jupyter Notebook não precisamos nos preocupar com a criação do Spark Context.

Anatomia de Uma Aplicação Spark

Quando utilizamos o PySpark e o Jupyter Notebook não precisamos nos preocupar com a criação do Spark Context.

Mas quando criamos uma aplicação de análise de dados (um arquivo .py por exemplo) e utilizamos o spark-submit para iniciar nossa aplicação, precisamos explicitamente criar um Spark Context.

Arquitetura Spark

Arquitetura Spark

chamada de MASTER-WORKER
O master gerencia e o worker executa

Arquitetura Spark Master/Worker

Driver Program: API para processo de análise do Spark (existe uma para cada linguagem)
Spark Context: cliente para conexão com o cluster
Cluster Manager: gerenciar recursos do cluster

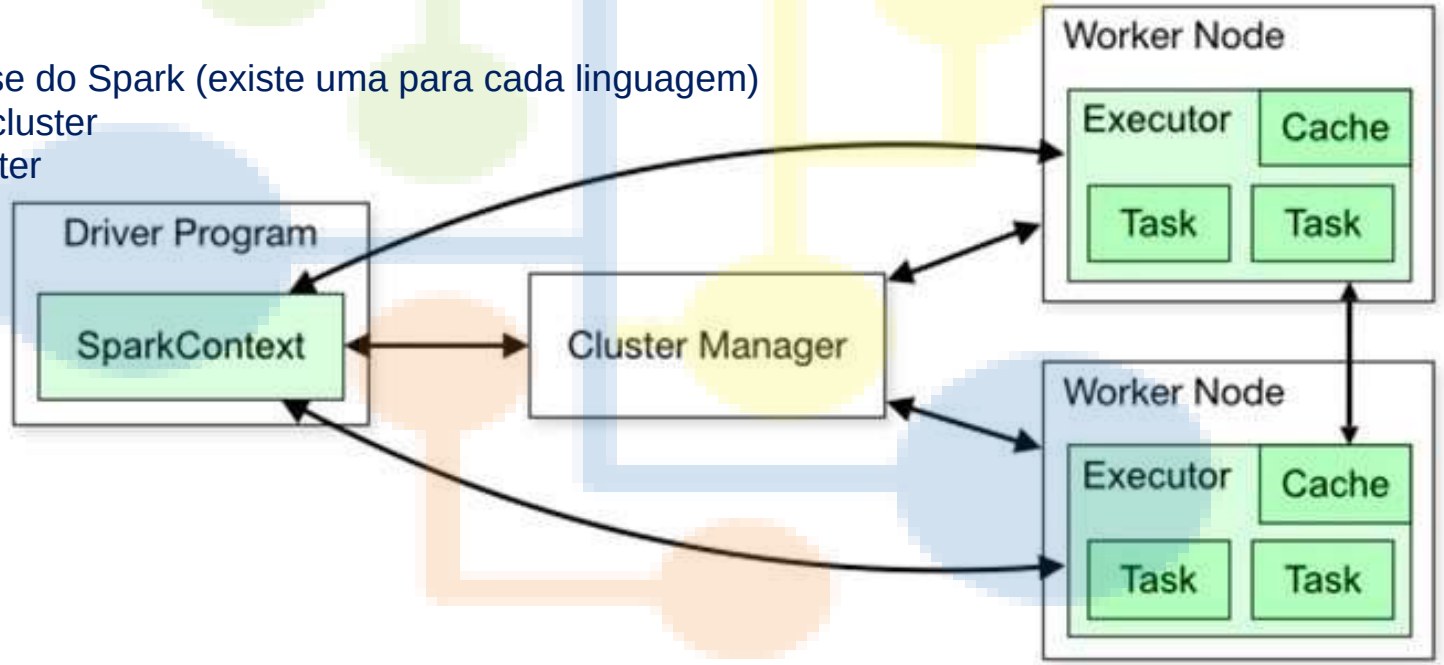

Arquitetura Spark

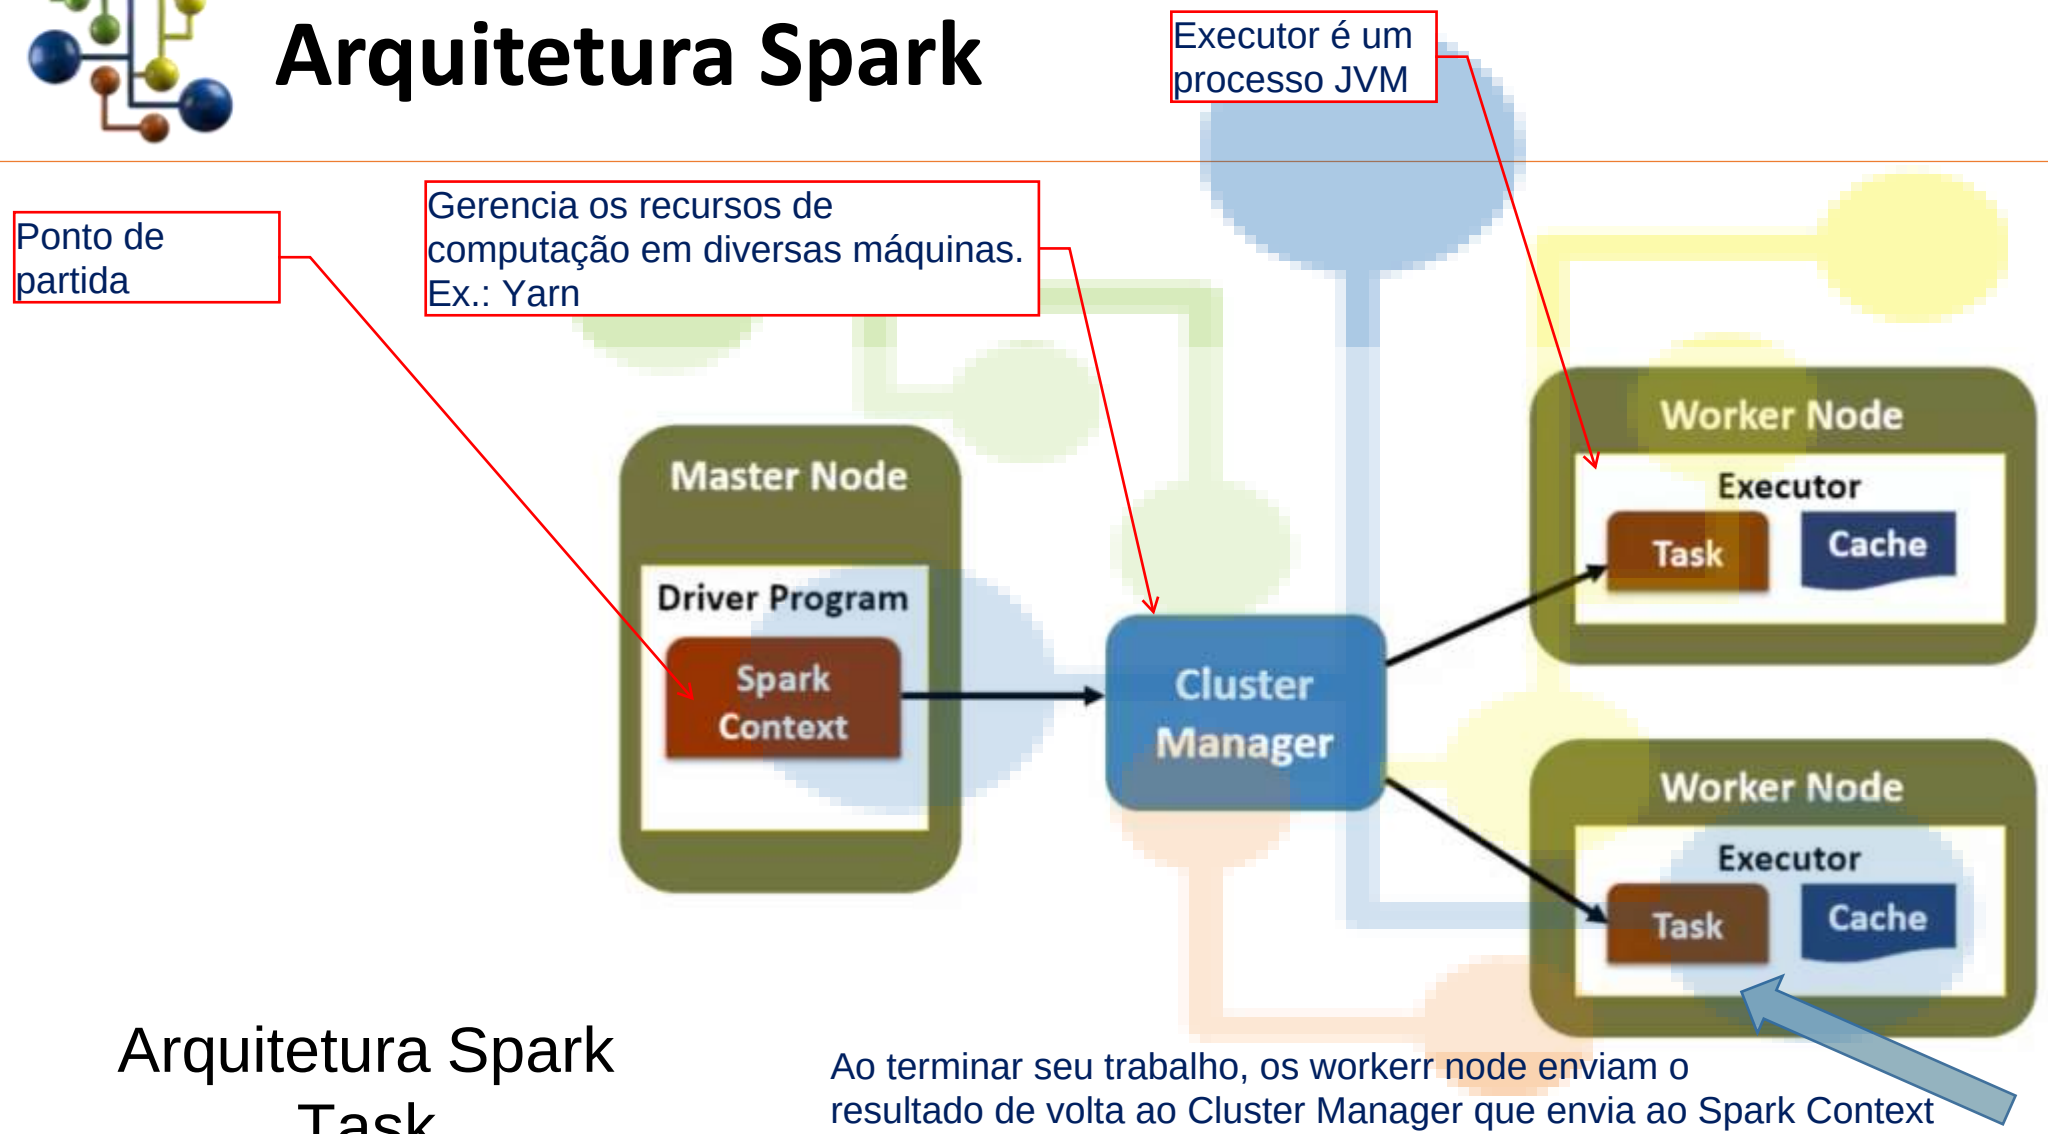

Arquitetura Spark
Task

Spark Modes

Spark Modes

Agendado para executar em intervalos específicos via scheduler

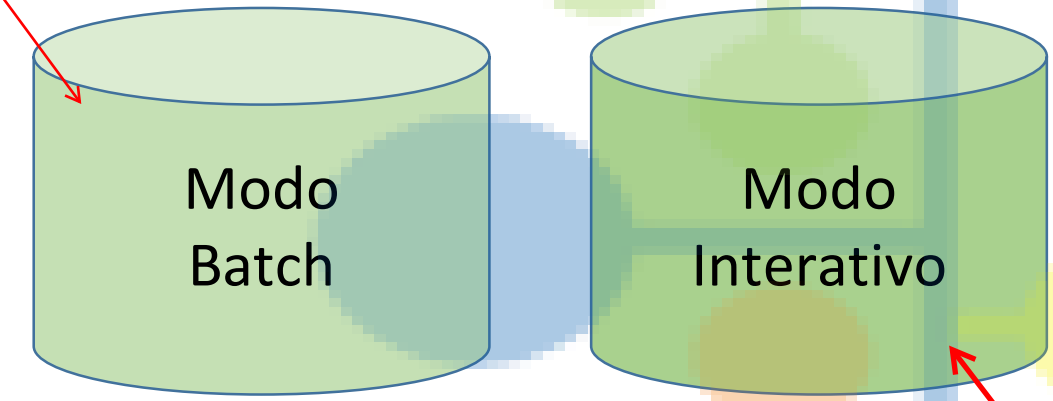

Utiliza o shell para executar comandos no cluster. O shell age como um driver program e provê um SparkContext.

Spark Modes

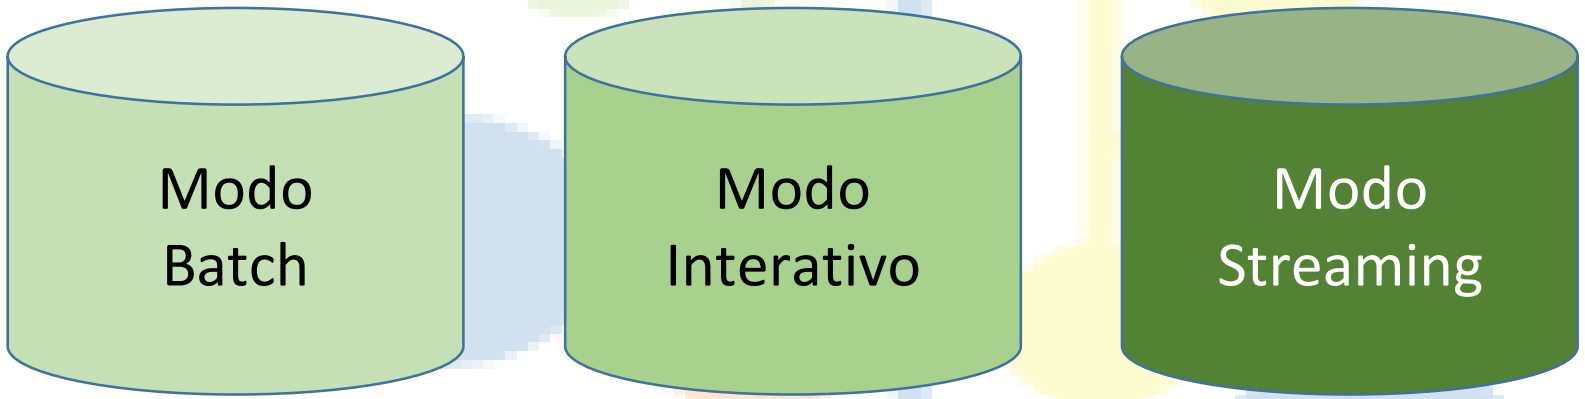

Um programa que executa continuamente para processar os dados à medida que eles chegam, em tempo real.

Deploy Mode e Fontes de Dados

Deploy Mode

Spark Mode → Modo de processamento de dados no Spark (Batch, Interativo ou Streaming).

Deploy Mode → Modo de execução do Spark. Em cada Deploy Mode podemos usar um ou mais Spark Modes.

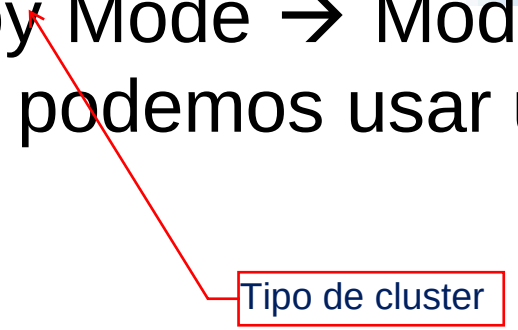

Deploy Mode

Local
(Standalone ou Cluster)

Cluster em Nuvem
(Databricks, Amazon EC2, IBM Bluemix)

Única JVM

Cluster Gerenciado

Exemplo: Yarn

Fontes de Dados

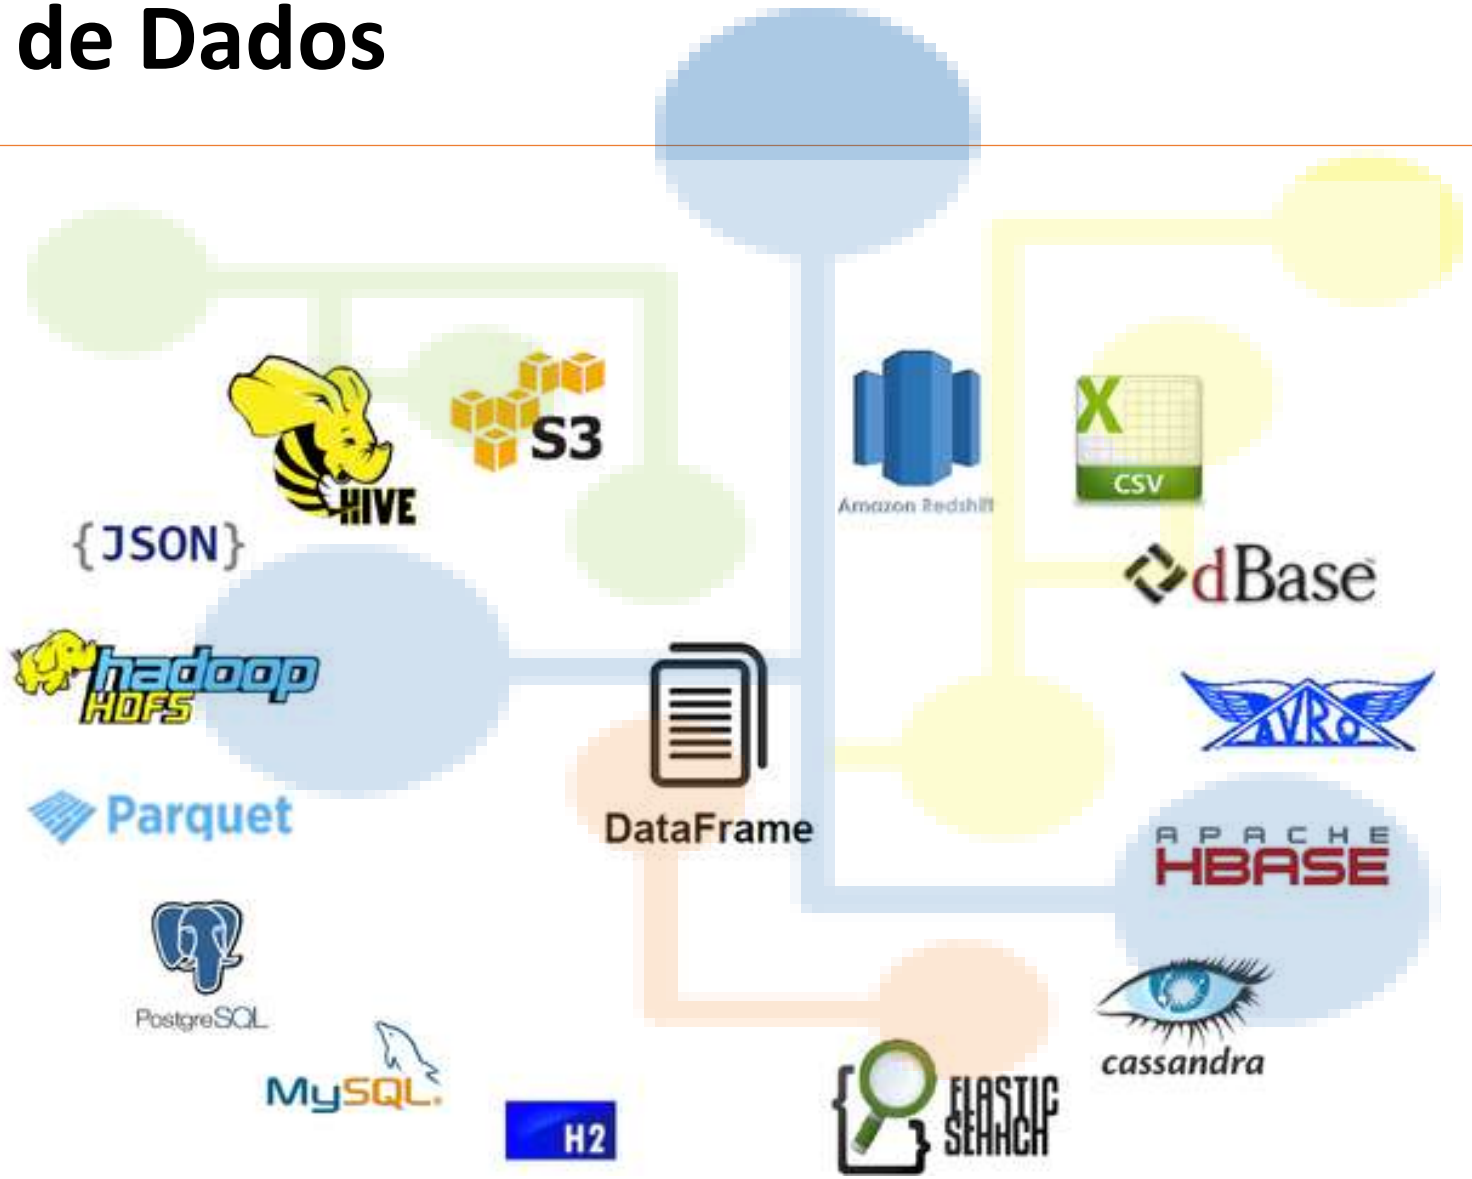

RDD's
Resilient Distributed Datasets

Objetiva permitir o processamento de dados em ambiente distribuído

Tudo em Spark depende do RDD

RDD's - Resilient Distributed Datasets

RDD pode conter objetos Scala, Python e Java

RDD é uma coleção de objetos, distribuída e imutável. Cada conjunto de dados no RDD é dividido em partições lógicas, que podem ser computados em diferentes nodes do cluster.

RDD's - Resilient Distributed Datasets

RDD’s são imutáveis!

Pois é uma estrutura distribuída

RDD's - Resilient Distributed Datasets

Fontes de dados

- Arquivos
- HDFS
- RDBMS
- NoSQL

Ação: executa todas as transformações na sequência, pois o processamento é distribuído

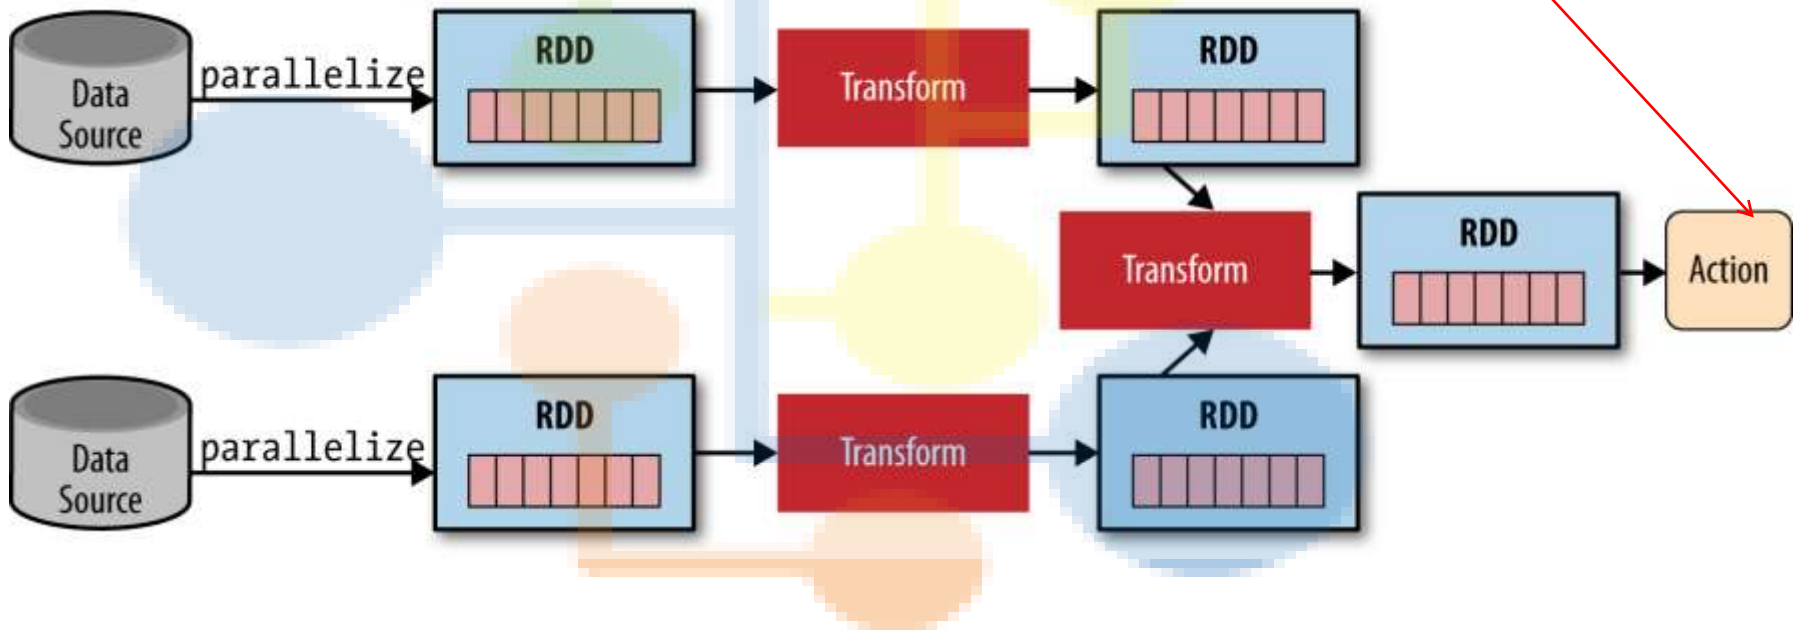

RDD's - Resilient Distributed Datasets

Existem 2 formas de criar o RDD

Paralelizando uma coleção existente
(função sc.parallelize)

Referenciando um dataset externo
(HDFS, RDBMS, NoSQL, S3)

RDD's - Resilient Distributed Datasets

As RDD’s são a essência do funcionamento do Spark

RDD's - Resilient Distributed Datasets

Armazena em disco somente no fim do processo

Apache Spark

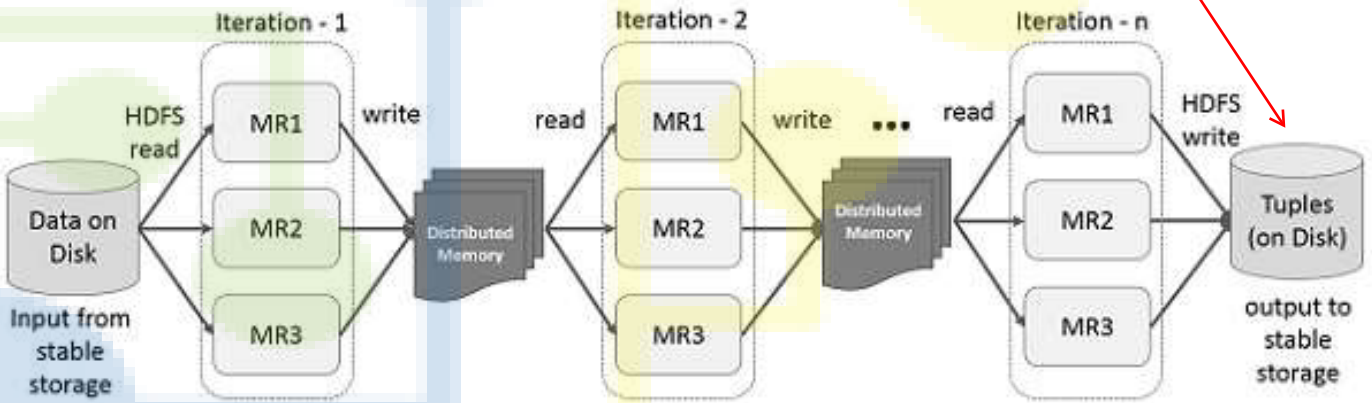

Cada resultado intermediário é gravado em disco

Hadoop MapReduce

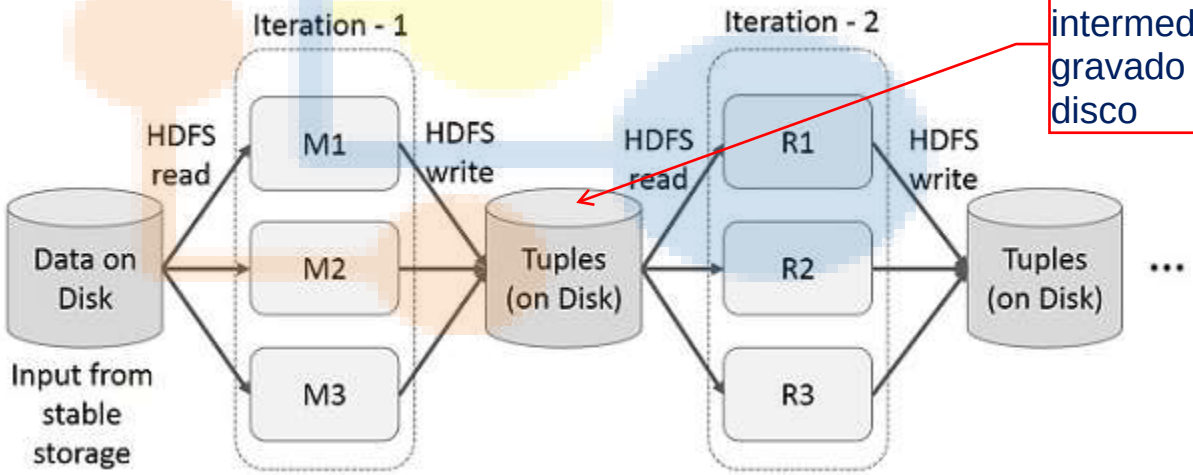

RDD's - Resilient Distributed Datasets

Por padrão, os RDD’s são computados cada vez que executamos uma Ação. Entretanto, podemos ”persistir” o RDD na memória (ou mesmo no disco) de modo que os dados estejam disponíveis ao longo do cluster e possam ser processados de forma muito mais rápida pelas operações de análise de dados criadas por você, Cientista de Dados.

RDD's - Resilient Distributed Datasets

O RDD suporta dois tipos de operações:

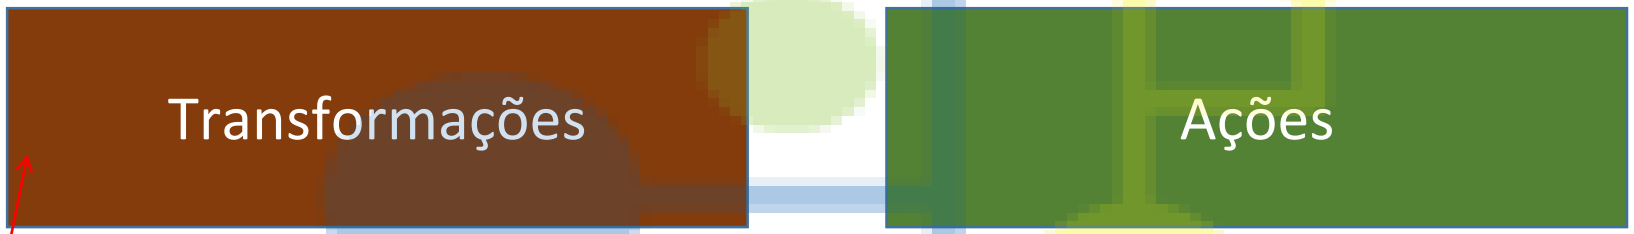

map()
filter()
flatMap()
reducedByKey()
aggregateByKey()

Outro RDD é criado a cada transformação

reduce()
collect()
first()
take()
countByKey()

RDD's - Resilient Distributed Datasets

Transformações e Ações

Transformations	Actions
map (func)	reduce(func)
flatMap(func)	collect()
filter(func)	count()
groupByKey()	first()
reduceByKey(func)	take(n)
mapValues(func)	saveAsTextFile(path)
sample(...)	countByKey()
union(other)	foreach(func)
distinct()	...
sortByKey()	
...	

RDD's - Resilient Distributed Datasets

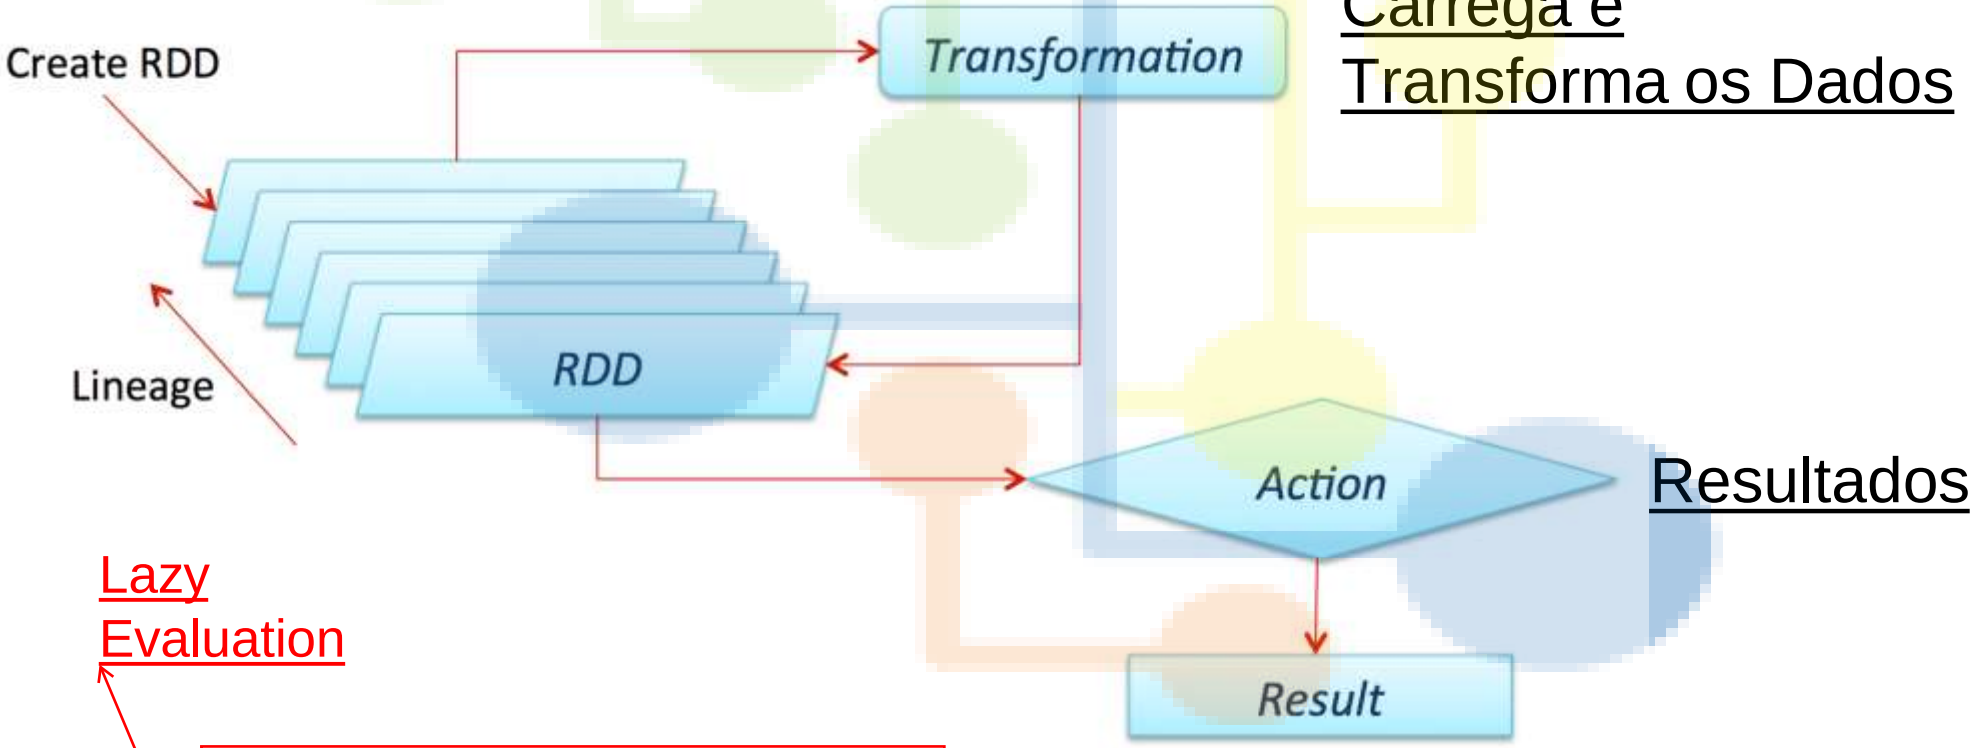

Carrega e Transforma os Dados

Resultados

Lazy Evaluation

Avaliação atrasada, pois a cada transformação nada é executado

RDD's - Resilient Distributed Datasets

As ”Ações” aplicam as ”Transformações” nos RDD’s e retornam resultado.

RDD's - Resilient Distributed Datasets

- Spark é baseado em RDD’s. Criamos, transformamos e armazenamos RDD’s com Spark.

RDD's - Resilient Distributed Datasets

- Spark é baseado em RDD’s. Criamos, transformamos e armazenamos RDD’s com Spark.
- RDD representa uma coleção de elementos de dados particionados que podem ser operados em paralelo.
- RDD’s são objetos imutáveis. Eles não podem ser alterados uma vez criados.
- RDD’s podem ser colocados em cache e permitem persistência (mesmo objeto usado entre sessões diferentes).
- Ao aplicarmos Transformações em RDD’s criamos novos RDD’s.

RDD's - Resilient Distributed Datasets

Portanto, as 3 características principais dos RDD's são:

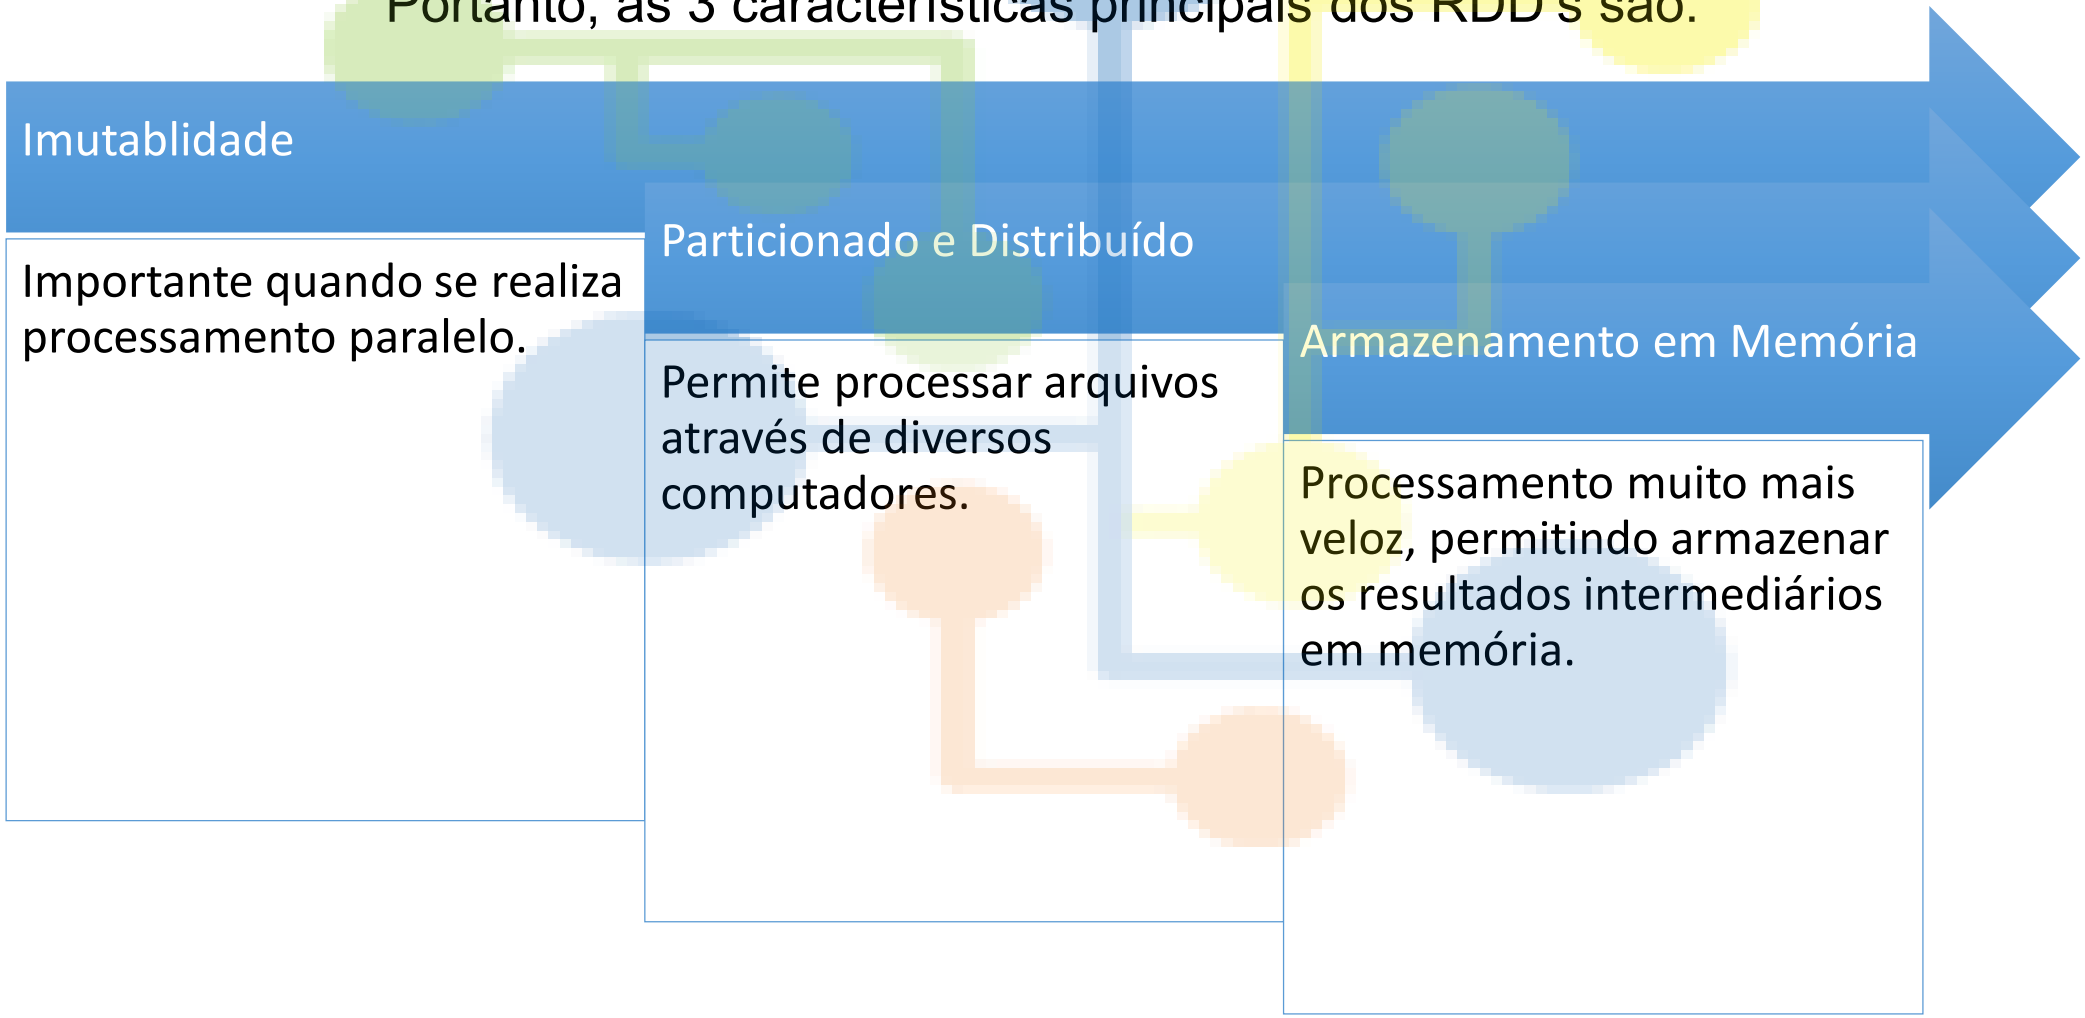

O Que São Transformações?

O Que São Transformações?

Transformações são “operações preguiçosas” (lazy operations) executadas sobre os RDD’s e que criam um ou mais RDD’s.

Transformações são funções que recebem um RDD de entrada e produzem um ou mais RDD de saída.
O conceito de lazy se deve ao fato de que a transformação não é processada quando se executa o comando, ela é apenas armazenada.
Mais tarde, quando se executa uma função de ação, todas as transformações são processadas e o resultao final é apresentado.

O Que São Transformações?

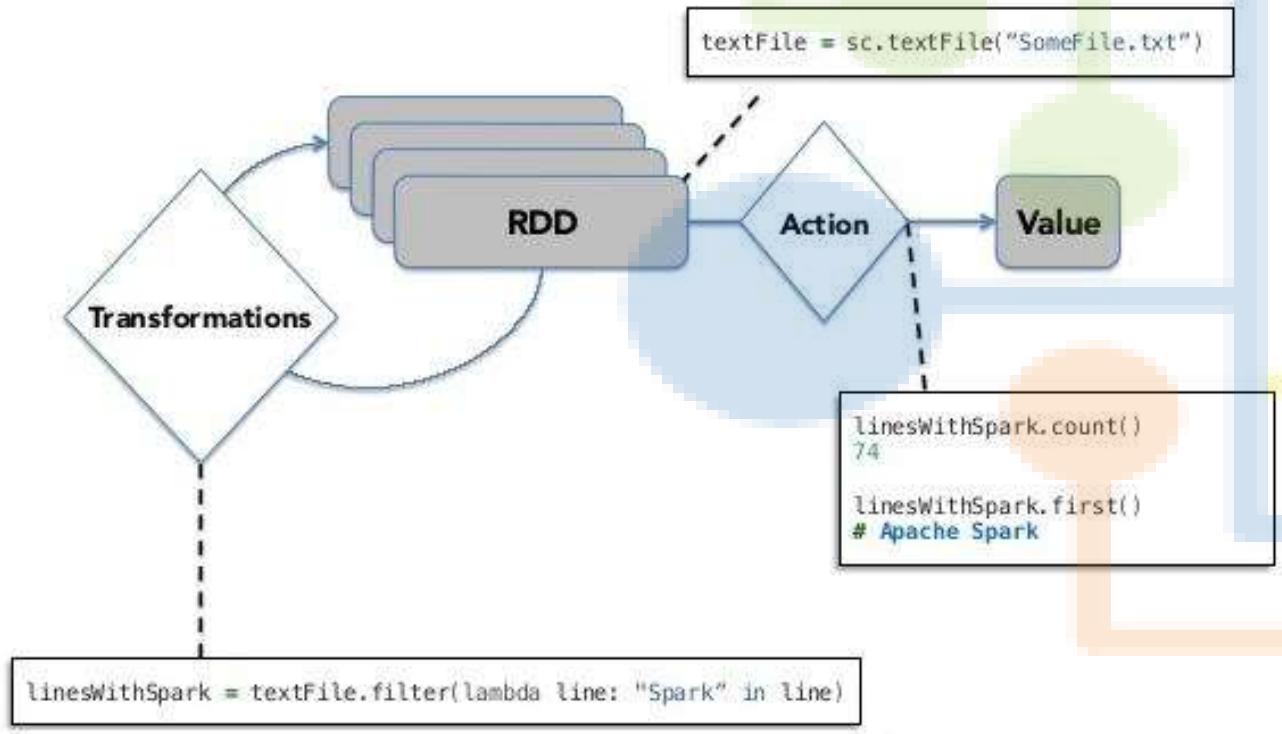

Dizemos que as transformações são operações lazy, porque elas não são executadas imediatamente, mas sim no momento em que as operações de ação são executadas.

O Que São Transformações?

Após executar operações de Transformação no RDD, o RDD resultante será diferente do RDD original e poderá ser menor (se usadas as funções filter, count, distinct, sample) ou maior (se usadas as funções flatMap, union, cartesian).

O Que São Transformações?

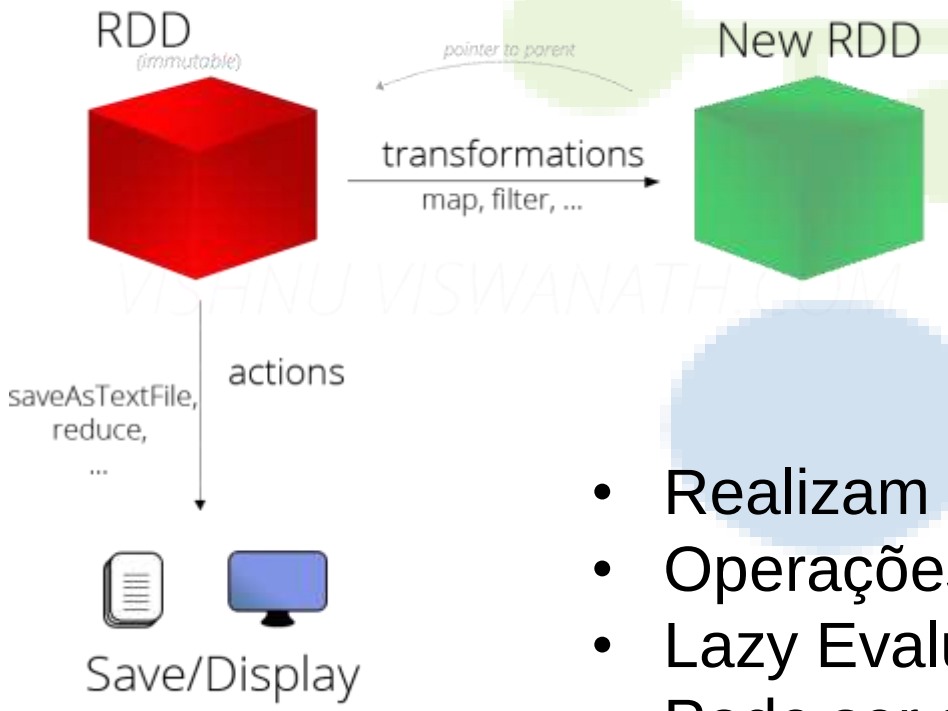

- Realizam as operações em um RDD e criam um novo RDD.
- Operações são feitas em um elemento por vez.
- Lazy Evaluation.
- Pode ser distribuída através de múltiplos nodes.

O Que São Transformações?

Algumas operações de Tranformação podem ser colocadas no que o Spark chama de Pipeline, que é um encadeamento de transformações visando aumentar a performance.

O Que São Transformações?

Estreitar

Narrow

Resultado de funções como map() e filter() e os dados vem de uma única partição.

Ampliar

Wide

Resultado de funções como groupByKey() e reduceByKey() e os dados podem vir de diversas partições.

Principais Operações de Transformação

Principais Operações de Transformação

Map

- Conceito de MapReduce
- Age sobre cada elemento e realiza a mesma operação

Exemplos:
- filtrar os dados
- buscar os dados por determinado padrão
- executar soma nos dados

Principais Operações de Transformação

flatMap

- Funciona como a função Map, mas retorna mais elementos

Principais Operações de Transformação

Filter

- Filtra um RDD para retornar elementos

Principais Operações de Transformação

Set

- São realizadas em duas RDD’s, com operações de união e interseção

Principais Operações de Transformação

mapPartitions

- Quando utilizamos como fontes de dados bancos de dados como Hbase ou Cassandra, temos dados armazenados com pares chave-valor. A transformação mapPartitions garante a atomicidade dos dados, evitando problemas de overhead na manipulação de dados e garantindo performance.

Principais Operações de Transformação

Lista com Todas as Operações de Transformação:

http://spark.apache.org/docs/latest/rdd-programming-guide.html#transformations

O Que São Ações?

O Que São Ações?

São operações executadas sobre os RDD’s que geram um resultado.

O Que São Ações?

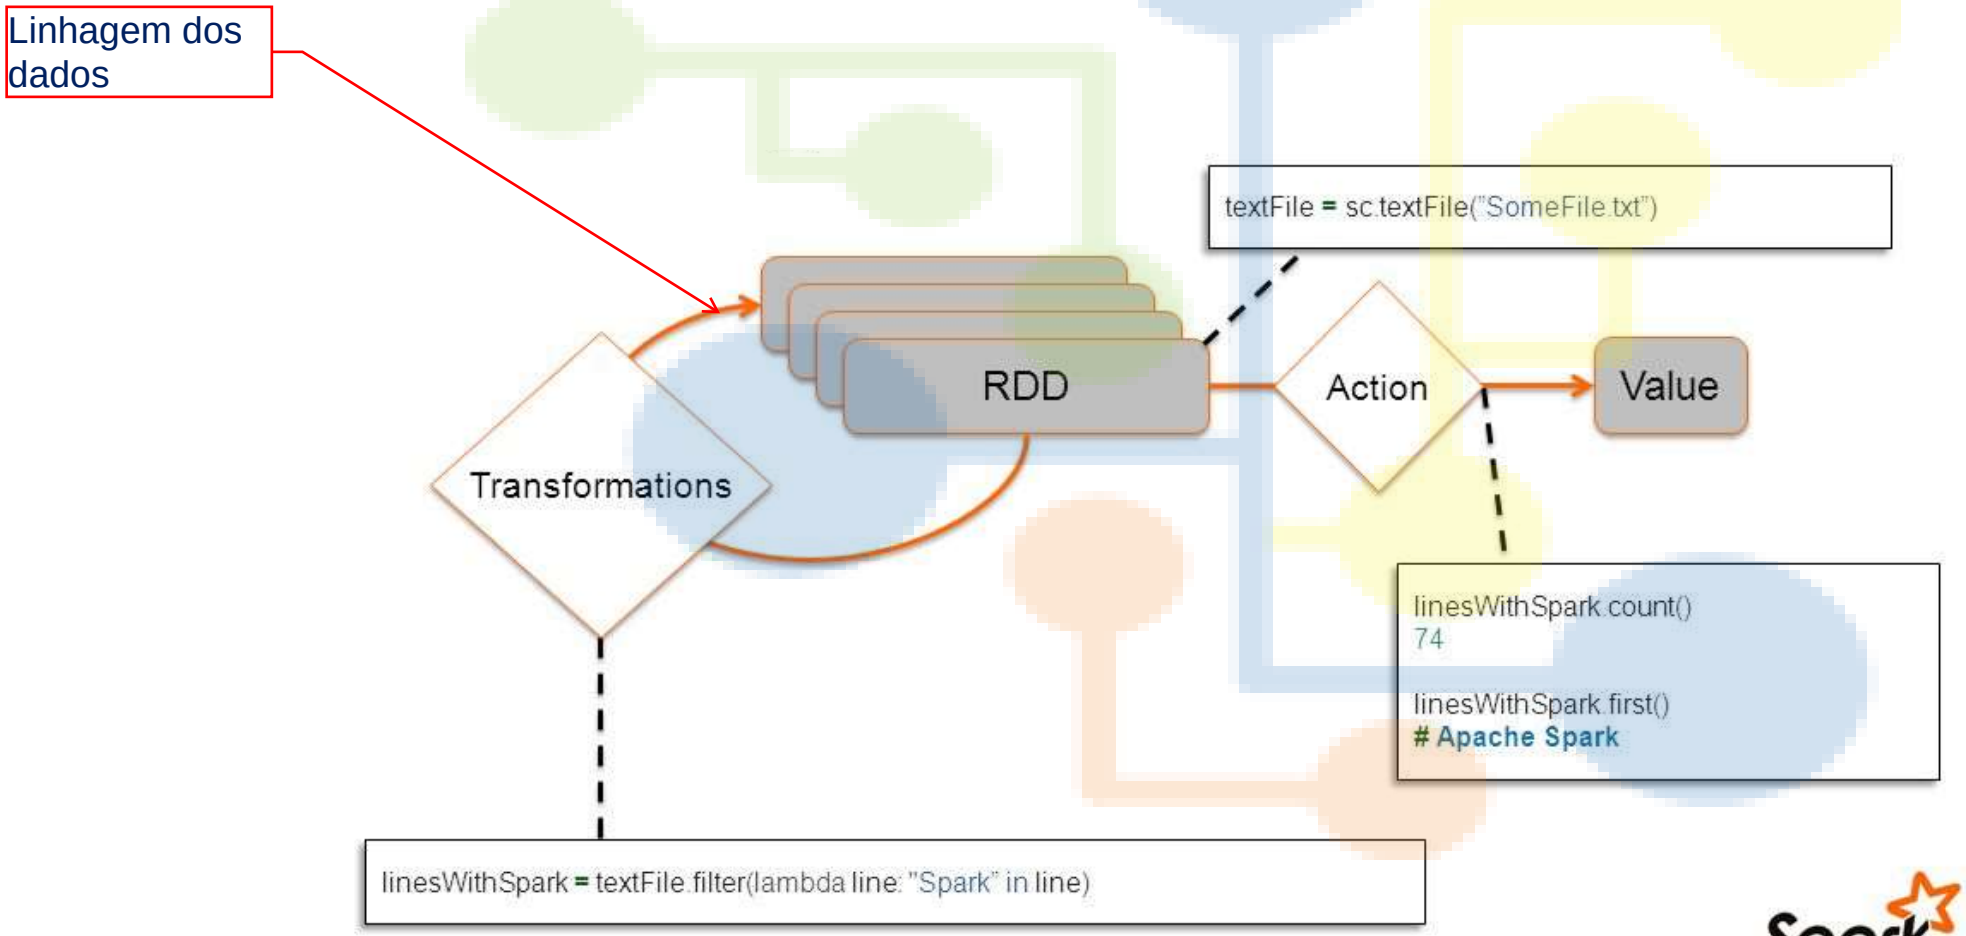

O Que São Ações?

Ações

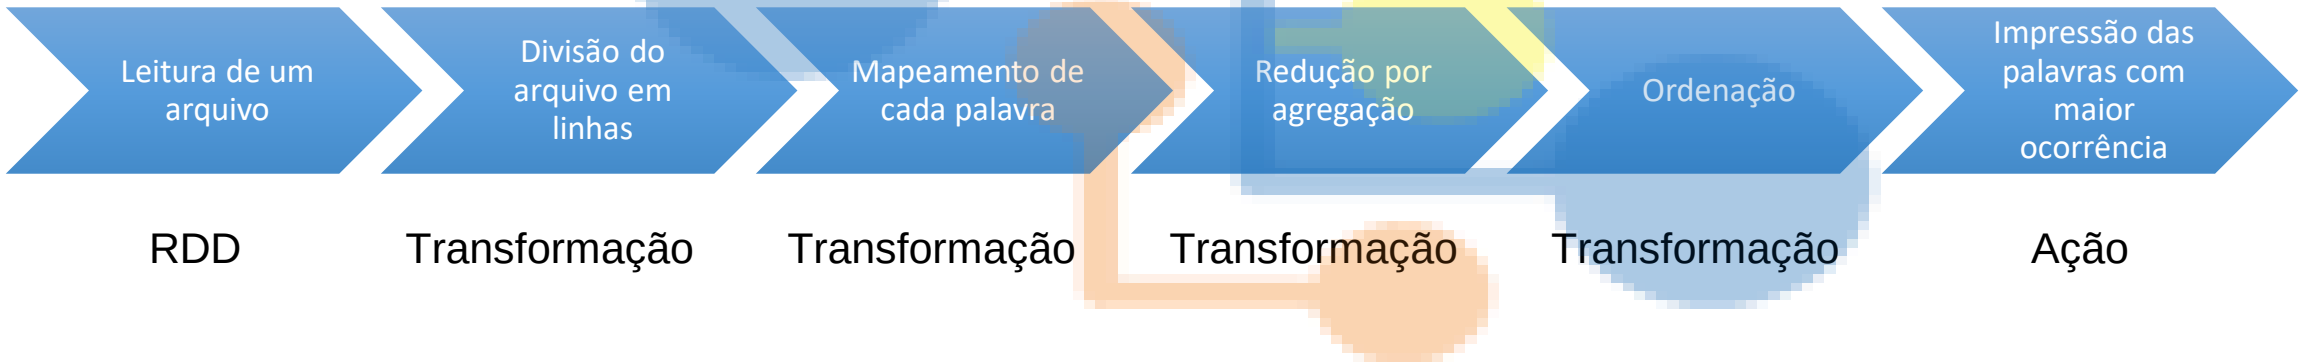

O Que São Ações?

Ações são operações síncronas mas podemos usar a função **AsyncRDDActions()** para tornar as operações assíncronas.

O Que São Ações?

Podemos pensar nas ações como válvulas. Os dados estão prontos para serem processados e operações de transformação já foram definidas, mas somente quando abrirmos as válvulas, ou seja, executarmos as ações, o processamento será realmente iniciado.

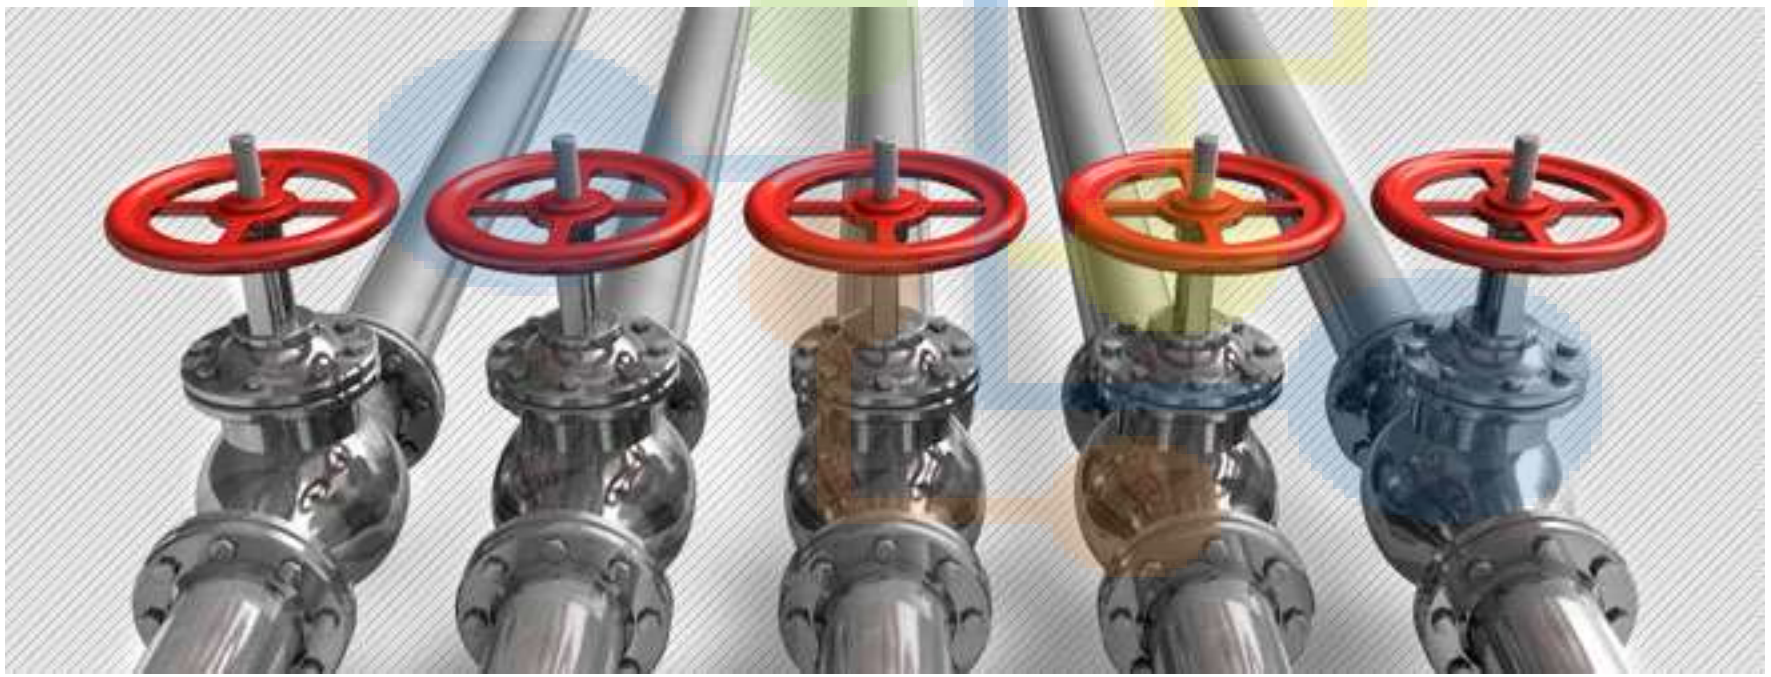

O Que São Ações?

O Spark oferece duas técnicas de otimização de performance: caching e persistence. Ambas armazenam resultados intermediários em memória, de forma que possam ser utilizados em estágios subsequentes dentro do processamento de dados.

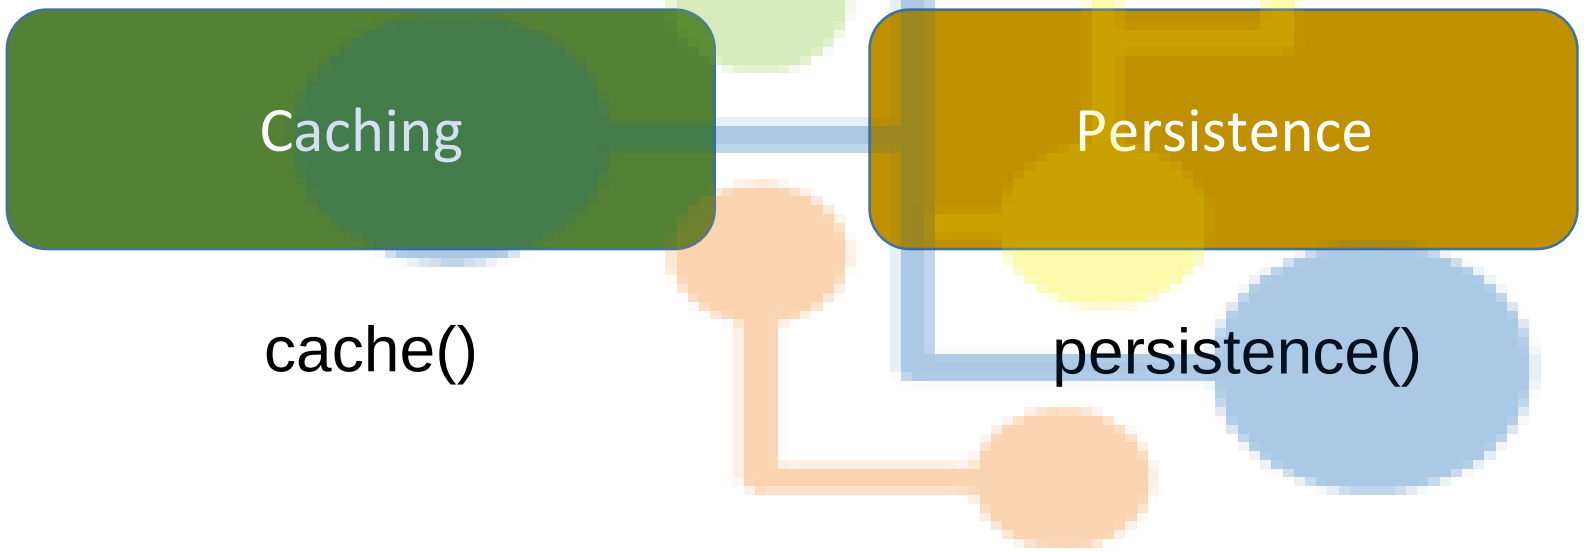

O Que São Ações?

Nós devemos colocar os RDD's em cache, sempre que for necessário executar duas ou mais Ações no conjunto de dados. Isso melhora a performance.

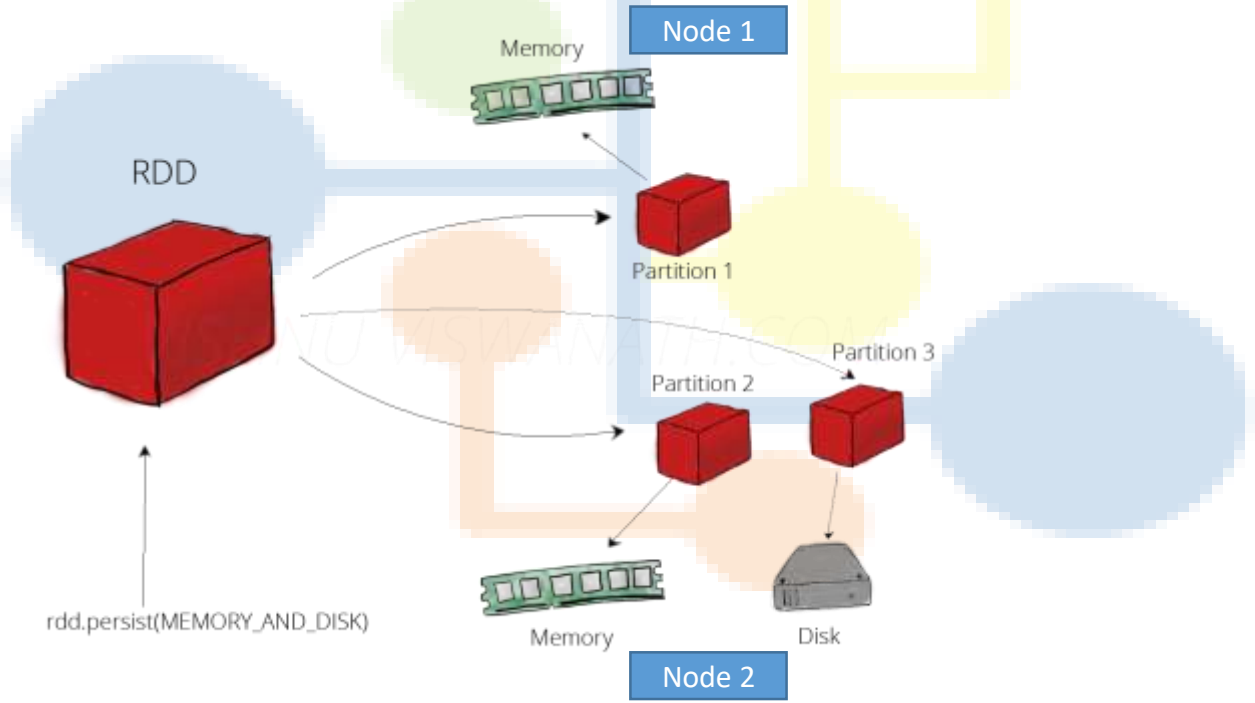

O Que São Ações?

Lista com Todas as Operações de Ação:

http://spark.apache.org/docs/latest/rdd-programming-guide.html#actions

Tenha uma Excelente Jornada de Aprendizagem.

Muito Obrigado por Participar!

Equipe Data Science Academy